HAW HAMBURG

BACHELOR THESIS
Raman Ahmad

Maschinelle Übersetzung für Low-Resource-Sprachen: Ein hybrider Ansatz zur Übersetzung für die Kobani-Variante des Kurmanji

FAKULTÄT INFORMATIK UND DIGITALE GESELLSCHAFT

Faculty of Computer Science and Digital Society

HOCHSCHULE FÜR ANGEWANDTE WISSENSCHAFTEN HAMBURG
Hamburg University of Applied Sciences

Raman Ahmad

Maschinelle Übersetzung für Low-Resource-Sprachen: Ein hybrider Ansatz zur Übersetzung für die Kobani-Variante des Kurmanji

Bachelorarbeit eingereicht im Rahmen der Bachelorprüfung
im Studiengang *Bachelor of Science Informatik Technischer Systeme*
der Fakultät Informatik und digitale Gesellschaft
der Hochschule für Angewandte Wissenschaften Hamburg

Betreuender Prüfer: Prof. Dr. Bettina Buth
Zweitgutachter: Prof. Dr. Peer Stelldinger

Eingereicht am: 21. Januar 2026

Raman Ahmad

Thema der Arbeit

Maschinelle Übersetzung für Low-Resource-Sprachen: Ein hybrider Ansatz zur Übersetzung für die Kobani-Variante des Kurmanji

Stichwörter

Maschinelle Übersetzung, Low-Resource-Sprachen, Kobani, synthetische Daten, Transfer Learning, Fine-tuning

Kurzzusammenfassung

Die Verfügbarkeit paralleler Trainingsdaten stellt eine der größten Herausforderungen bei der maschinellen Übersetzung (MT) für Low-Resource-Sprachen (LRLs) dar. Die Kobani-Variante (KV) des Kurmanji ist eine der LRLs, die noch nicht untersucht wurden und für die keine MT-Modelle entwickelt wurden. In dieser Arbeit wurde ein erstes fine-tuned Übersetzungsmodell für die KV entwickelt. Zur Bewältigung der Datenknappheit für die KV wurden synthetische Daten mithilfe eines Regelbasierten Ansatzes erstellt. Es wurden die NLLB-Daten genommen und diese anhand voridentifizierte linguistischen Regeln und einem Worterbuch für die KV perturbiert. Auf Basis dieser synthetischen Daten wurde das NLLB-200-distilled-600M-Modell mittels Transfer Learning an die KV angepasst.

Raman Ahmad

Title of Thesis

Machine Translation for Low-Resource Languages: A Hybrid Approach to Translation for the Kobani Variant of Kurmanji

Keywords

Machine Translation, Low-Resource Languages, Kobani, Synthetic Data, Transfer Learning, Fine-tuning

Abstract

The availability of parallel training data is one of the biggest challenges in machine translation (MT) for low-resource languages (LRLs). The Kobani variant (KV) of Kurmanji is one of the LRLs that has not yet been studied and for which no MT models have been developed. In this work, a first fine-tuned translation model for KV was developed. To address the data scarcity for KV, synthetic data were created using a rule-based approach. The NLLB data were taken and perturbed using pre-identified linguistic rules and a dictionary for KV. Based on this synthetic data, the NLLB-200-distilled-600M model was adapted to KV using transfer learning.

Inhaltsverzeichnis

Abbildungsverzeichnis **vii**

Tabellenverzeichnis **viii**

Listings **x**

Danksagung **1**

Abkürzungsverzeichnis **2**

1 Einleitung **3**

1.1 Motivation und Hintergrund 3
1.2 Problemstellung 4
1.3 Zielsetzung 5
1.4 Forschungsfragen 5
1.5 Aufbau der Arbeit 7

2 Theorie **8**

2.1 Maschinelle Übersetzung 8
2.2 Herausforderungen bei Low-Resource-Sprachen 10
2.3 Linguistische Besonderheiten der Kobani-Variante des Kurmanji 11
2.3.1 Lexik 12
2.3.2 Morphologie 12
2.3.3 Phonetik 15
2.4 Stand der Technik für kurdische MT 15

3 Datensammlung und -aufbereitung **17**

3.1 Beschreibung und Analyse der gesammelten Daten 17
3.2 Datenbereinigung und Vorverarbeitung 18
3.3 Herausforderungen bei der Datenknappheit 20

4 Methodik **21**
4.1 Regelbasierter Ansatz 21
4.2 Linguistische Regeln und Wörterbuch 21
4.3 Implementierung des regelbasierten Perturbationssystems 22
4.3.1 Linguistische Regeln 22
4.3.2 Wörterbuch 23
4.4 Transfer-Learning-Ansatz 24
4.5 Auswahl des vortrainierten Modells 24
4.6 Fine-tuning auf Kobani-Daten 25
4.7 Kombination von regelbasiertem Ansatz und Transfer-Learning 26

5 Evaluation **27**
5.1 Automatische Metriken 27
5.2 Durchführung der Experimente 28
5.3 Ergebnisse des NLLB-Base-Modells und des fine-tuned Modells 28
5.4 Analyse und Diskussion der Übersetzungsergebnisse 29

6 Fazit und Ausblick **33**
6.1 Zusammenfassung der wichtigsten Erkenntnisse 33
6.2 Beantwortung der Forschungsfragen 34
6.2.1 Forschungsfrage 1 34
6.2.2 Forschungsfrage 2 34
6.3 Limitationen der Arbeit 35
6.4 Übertragbarkeit und zukünftige Forschung 36

Literaturverzeichnis **37**

A Anhang **44**
A.1 OpusCleaner Filters 44
A.1.1 OpusFilter Ergebniss 46
A.2 Hyperparameter des Fine-tunings 47
A.3 Übersetzungsergebnisse 47
A.4 Glossar 49
A.5 Verwendete Hilfsmittel 50

Selbstständigkeitserklärung **51**

Abbildungsverzeichnis

1.1 Konzept dieser Arbeit 6

2.1 NMT – Encoder und Decoder 10
2.2 Architektur des Transformer-Modells 11

4.1 Traditionelles Lernen im Vergleich zum Transfer-Learning 25

5.1 TER-Vergleich: Base vs. Fine-tuned NLLB-200-distilled-600M 30
5.2 BLEU-Vergleich: Base vs. Fine-tuned NLLB-200-distilled-600M 30
5.3 chrf++-Vergleich: Base vs. Fine-tuned NLLB-200-distilled-600M 31

Tabellenverzeichnis

1.1 Unterschiede in der Kopula-Konstruktion zwischen Kurmanji und Kobani . . . 4

2.1 Lexikalische Unterschiede zwischen Kurmanji und der Kobani-Variante 12
2.2 Präpositionen im Kurmanji und in der Kobani-Variante. 12
2.3 Verbkonjugation (3. Person Sg.) in der Kobani-Variante 13
2.4 Kopulaphrasen in der Kobani-Variante 13
2.5 Ezafe-Konstruktion in der Kobani-Variante 13
2.6 Zukunftsform in der KV 14
2.7 Nomen nach Demonstrativpronomen in der KV 14
2.8 Nomen nach Demonstrativpronomen in Kopulaphrasen in der Kobani-Variante. 14
2.9 Vokalverschmelzung in der KV (ey/êy/iyê → ê) 15
2.10 Lautveränderungen in der Kobani-Variante 15

3.1 Statistiken des NLLB Kurmanji-Englisch-Datensatzes 17
3.2 Beispiele für Fehlerarten in Satzpaaren 18
3.3 Filter in OpusCleaner mit Beispielen für Englisch–Kurmanji 18
3.4 Steuerzeichen und Kodierungsfehler im Kurmanji-Korpus 19

4.1 Statistik der regelbasierten Vorverarbeitung 23
4.3 Anwendung von Regeln und Wörterbuch auf einen Kurmanji-Satz. 23
4.2 Nomendeklination nach Kasus bei der regelbasierten Perturbation von Kurmanji- zu Kobani-Wörtern 24

5.1 Übersetzungsqualität des NLLB-Base-Modells und des fine-getunten Modells . 28
5.2 Repräsentative Übersetzungsbeispiele mit Referenz und Modellhypothese . . . 32

A.1 Alle Filters in OpusCleaner mit Beispielen für Englisch-Kurmanji 46
A.2 Alle ausgewählten Übersetzungsbeispiele: Referenz vs. Modellhypothese . . . 47
A.3 Verwendete Hilfsmittel und Werkzeuge 50

Listings

A.1 Konfiguration der in opusCleaner verwendeten Filter 44
A.2 Hyperparameter-Konfiguration des Fine-tunings (beide Übersetzungsrichtungen identisch) 47

Danksagung

Ich möchte mich hiermit bei allen bedanken, die mich bei dieser Bachelorarbeit begleitet und unterstützt haben.
Vielen Dank an **Christian Schuler**, der mich seit dem ersten Tag dieser Arbeit bis zum Ende betreut hat und stets für mich da war. Durch seine wertvolle und kontinuierliche Unterstützung konnte ich die Herausforderungen dieser Arbeit erfolgreich bewältigen.

Vielen Dank an **Bettina Buth**, die durch ihre fachliche Expertise und wertvolle Rückmeldungen maßgeblich zur Qualität dieser Arbeit beigetragen hat.

Mein Dank gilt auch meinen Eltern, **Adla Damijar** und **Abdo Ahmad**, die mir stets zur Seite standen und mir bei Fragen spezifische Begriffe aus Kobani erklärt haben.

Abkürzungsverzeichnis

MT Machine Translation (Maschinelle Übersetzung)

KV Kobani-Variante

LRLs Low-Resource-Languages (Ressourcenarme Sprachen)

NLP Natural Language Processing (Verarbeitung natürlicher Sprache)

SK Standard-Kurmanji

RBA Regelbasierter Ansatz

PoS Part-of-Speech

TL Transfer Learning (Transferlernen)

1 Einleitung

Maschinelle Übersetzung (MT) hat sich in den letzten Jahren zu einem wichtigen Instrument im interkulturellen Austausch entwickelt. Für viele weltweit verbreitete Sprachen zeigen moderne MT-Systeme bereits beachtliche Leistungen. Sprachen mit geringen digitalen Textressourcen – sogenannte LRLs – bleiben jedoch weitgehend unterrepräsentiert [20, 17]. Dies gilt auch für Kurdisch, das trotz etwa 30 Millionen Sprecher:innen in mehreren Ländern zu den ressourcenarmen Sprachen zählt [15]. Dies gilt insbesondere in seinen regionalen Varianten [1].

Die kurdische KV, die im nordsyrischen Raum gesprochen wird, ist bislang noch nicht in der Forschung zu MT berücksichtigt worden. Es fehlen sowohl digitale Sprachressourcen als auch angepasste MT-Modelle. Dies erschwert den Zugang zu digitalen Inhalten und schränkt die sprachliche Sichtbarkeit dieser Gemeinschaft im digitalen Raum ein [7]. In dieser Arbeit werden die spezifischen Herausforderungen und Potenziale von MT für die KV untersucht. Dabei sollen sowohl linguistische Besonderheiten (z.B. morphologische Strukturen oder Orthographievarianten) als auch technische Voraussetzungen (z.B. Datenverfügbarkeit oder Modellwahl) betrachtet werden [19].

1.1 Motivation und Hintergrund

Kobani ist eine kurdische Stadt in Nordsyrien, die laut Schätzungen[1] aus dem Jahr 2013 etwa 45.000 Einwohner zählt. Die Bevölkerung ist kurdischer Herkunft und die gesprochene Sprache gehört zum Kurmanji (Nordkurdisch) [14]. Die KV unterscheidet sich in verschiedenen morphologischen und lexikalischen Merkmalen von anderen Varianten.

Beispielsweise wird im Kobani-Dialekt die dritte Person Singular durch das Suffix-**ê** markiert. Außerdem zeigen die Kopulasätze einen Marker, der gleichzeitig drei linguistische Kategorien kodiert (Genus, Numerus und Aspekt) siehe Tabelle 1.1. Mit solchen morphosyntaxischen

[1] https://en.wikipedia.org/wiki/Kobani#:~:text=Prior%20to%20the%20Syrian%20Civil,8

Besonderheiten habe ich mich bereits in Voruntersuchungen befasst, deren Ergebnisse als Poster[2] auf der ICKL-6[3] präsentiert wurden. Im Zuge einer Folgeuntersuchung habe ich neue Erkentnisse erlangt, welche als Beitrag für die Poster-Session der ICKL-7[4] akzeptiert wurden.

Alle diese Vorarbeiten haben sowohl das wissenschaftliche Interesse an der KV als auch die Herausforderungen ihrer Analyse und Beschreibung aufgezeigt und bilden damit die Grundlage für die vorliegende Untersuchung.

Tabelle 1.1: Unterschiede in der Kopula-Konstruktion zwischen Kurmanji und Kobani

Sprache	**Linguistische Merkmale**		
Kurmanji	Heyv 3SG	sipî ADJ.	ye 3SG.COP, Present
Kobani	Hîv-**e** 3SG. -TEMP(Izafa)	**gewr** ADJ.	e 3SG.COP, Present
Deutsch	Der Mond	weiß	ist → (Der Mond ist weiß)

1.2 Problemstellung

Die Entwicklung eines MT-Systems für die KV stellt mehrere signifikante Herausforderungen dar. Die Ressourcenknappheit ist ein zentrales Problem, da nur wenige digitalisierte Daten für die KV verfügbar sind, was das Training von Modellen erschwert [20]. Derzeit existiert nur ein kleiner paralleler Textkorpus, der im Rahmen eines Studierendenprojekts[5] erstellt wurde.

Die fehlende standardisierte Schriftform der KV erschwert die Textanalyse und das Modelltraining, während die komplexe morphologische Struktur eine weitere Herausforderung darstellt. Die Evaluierung der Übersetzungsqualität stellt eine weitere Hürde dar, da Standard-Übersetzungen fehlen und qualifizierte menschliche Evaluatoren schwer verfügbar sind. Bewertungsmethoden wie BLEU [30] oder ChrF [32] sind für nicht-standardisierte Sprachen wie KV nur begrenzt anwendbar, was die Qualitätsbewertung zusätzlich kompliziert.

[2] https://christianschuler8989.github.io/docs/posters/2023_Ahmad_Schuler_ICKL_KobaniAnalysis_Poster.pdf
[3] https://ickl-conference.org/
[4] https://ickl-conference.org/wp-content/uploads/ICKL-7_Booklet.pdf
[5] https://lecture2go.uni-hamburg.de/l2go/-/get/l/7444

1.3 Zielsetzung

Ziel dieser Arbeit ist die Entwicklung eines Übersetzungssystems für die KV, siehe Abbildung 1.1. Bei der Entwicklung eines solchen Systems besteht eine zentrale Herausforderung im Low-Resource-Status der KV, da nur wenig parallel annotierte Textdaten vorhanden sind (MTACR[6]). Und gerade deswegen verfolgt diese Arbeit einen zweigleisigen Ansatz, um ein funktionales Übersetzungssystem trotz Datenknappheit zu entwicklen. Erstens wird ein regelbasiertes System implementiert, das die Kurmanji-Daten durch linguistische Regeln und ein selbst erstelltes Wörterbuch an die KV systematisch anpasst, siehe Abschnitt 4.2. Zweitens erfolgt die Anpassung eines vortrainierten Modells mittels Transfer Learning auf die Kobani-Daten. Dieses System soll eine Ausgangslösung für weiterführende MT-Forschung im Bereich kurdischer Dialekte bieten.

1.4 Forschungsfragen

In dieser Arbeit sollen die folgenden drei Forschungsfragen untersucht werden:

1. Inwiefern kann ein regelbasiertes Perturbationssystem für die maschinelle Übersetzung zwischen Englisch und Kobani-Variante entwickelt werden, das auf einem Wörterbuch aufbaut und linguistische Merkmale systematisch verwendet, um die Datenknappheit zu überwinden?

2. Wie gut lässt sich das vortrainierte Übersetzungsmodell (NLLB-200-distilled-600M-Modell [40]), das bereits Englisch-Kurmanji unterstützt, durch Transfer Learning auf die synthetischen Kobani-Daten anpassen, um eine hohe Übersetzungsqualität zu erreichen?

[6] Ziel des Projekts war es, Textdaten zu sammeln und zu pflegen, um die Verarbeitung natürlicher Sprache (unter anderem KV) zu unterstützen: https://www.hcl.uni-hamburg.de/ddlitlab/data-literacy-studierendenprojekte/dritte-foerderrunde/textcorpus.html

Abbildung 1.1: Konzept dieser Arbeit

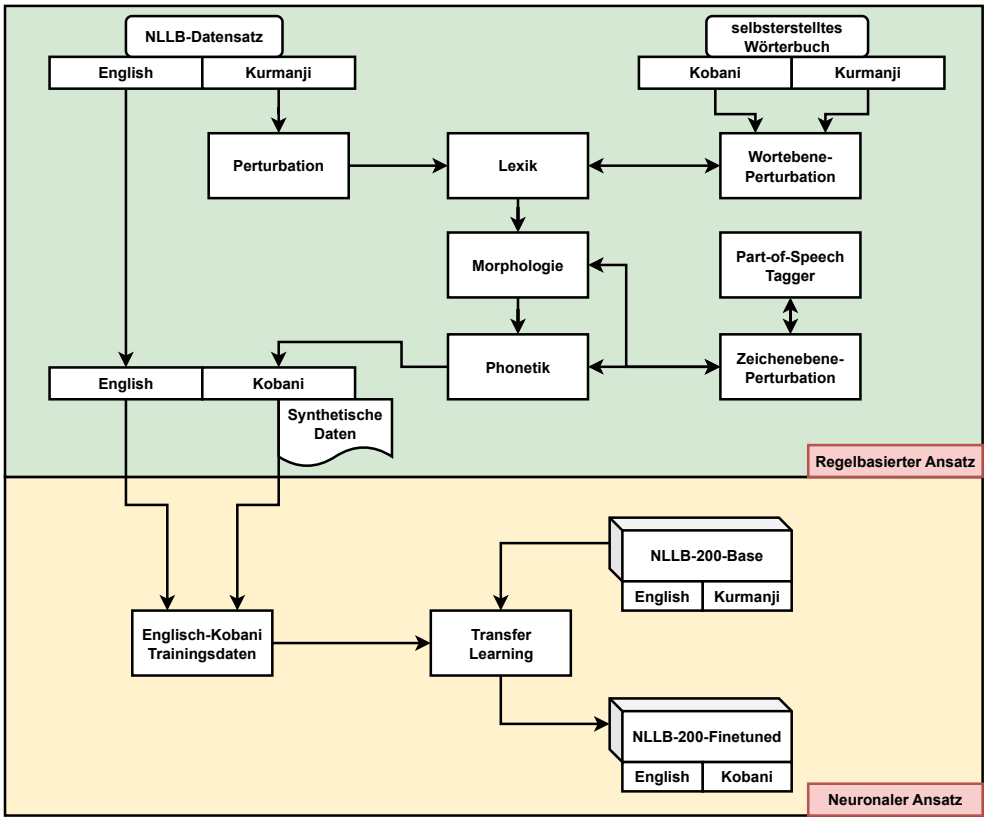

1.5 Aufbau der Arbeit

Diese Arbeit besteht aus 8 Kapiteln und ist wie folgt aufgebaut:

In dem ersten Kapitel wird die Motivation, die Problemstellung und die Zielsetzung beschrieben und die Forschungsfragen formuliert.

Im zweiten Kapitel werden die theoretischen Grundlagen der MT dargestellt. Es werden neben allgemeinen Konzepten die Herausforderungen von LRLs sowie linguistische Besonderheiten der KV und der aktuelle Stand der Technik behandelt.

Im dritten Kapitel wird die Datensammlung und -aufbereitung beschrieben. Die verwendeten Daten werden analysiert, die Vorverarbeitung erläutert und die bestehenden Herausforderungen durch Datenknappheit diskutiert.

Im vierten Kapitel wird die Methodik dieser Arbeit dargestellt. Zuerst wird der regelbasierte Ansatz beschrieben, gefolgt von der Beschreibung linguistischer Regeln der KV und des verwendeten Wörterbuchs. Danach wird der Transfer-Learning-Ansatz vorgestellt. Anschließend wird die Modellauswahl, das Fine-tuning auf Kobani-Daten sowie die Kombination beider Ansätze erläutert.

Im fünften Kapitel wird die Evaluation der Übersetzungsqualität des fine-tuned Modells vorgestellt und die automatischen Metriken sowie die Testfälle diskutiert.

Im sechsten Kapitel werden die wichtigsten Erkenntnisse zusammengefasst, die Forschungsfragen beantwortet und die Limitation des hybriden Ansatzes reflektiert. Anschließend werden Perspektiven für zukünftige Forschun aufgezeigt.

Im siebten Kapitel enthält den Anhang mit zusätzlichen Materialien, darunter detaillierte Tabellen zur OpusCleaner-Einstellungen, Hyperparameter-Listen des Fine-Tunings und weitere qualitative Übersetzungsbeispiele.

2 Theorie

2.1 Maschinelle Übersetzung

MT ermöglicht die automatische Übersetzung von Texten einer Sprache in eine andere. Ziel ist es, die Kommunikation und das Verständnis zwischen Personen, die unterschiedliche Sprachen sprechen, zu erleichtern und so den Austausch von Informationen, Ideen und Wissen über Sprachgrenzen hinweg zu ermöglichen [27]. Dabei werden, abhängig von der Aufgabe oder Szenario, unterschiedliche Ansätze angewendet.

Laut [27] können moderne MT-Systeme im Wesentlichen in drei Ansätze eingeteilt werden:

1. **Regelbasierte maschinelle Übersetzung (RBMT)**:

   RBMT war der erste Ansatz der MT und prägte die Entwicklung dieser Technologie maßgeblich, auch wenn die Systeme anfangs noch viele Einschränkungen aufwiesen [23]. Bei diesem Ansatz erfolgt die Übersetzung zwischen Sprachen mithilfe definierter linguistischer Regeln und eines zweisprachigen Wörterbuchs. Die Texte werden systematisch mithilfe der linguistischen Regeln (Morphologie, Syntax und Lexikon) von einer Ausgangs- in eine Zielsprache überführt.

   Regelbasierte Modelle brauchen keine fertigen Übersetzungen, da sie mit festen Sprachregeln arbeiten - zum Beispiel: ***Baum*** (deu) = ***Tree*** (eng). Ein großes Problem dabei ist jedoch, dass sie schnell an Grenzen stoßen, da Wörter kontextabhängig sind. Bei einer Wort-für-Wort-Übersetzung kann das System beispielsweise nicht erkennen, ob ***Band*** (deu) eine Musikgruppe oder ein Buch-***Band*** (deu) meint. Ein weiterer Nachteil besteht darin, dass oft keine passende zweisprachigen Wörterbücher vorhanden sind und die Erstellung neuer Wörterbücher zeitaufwändig[1] sein kann.

[1] https://www.rws.com/industries/legal/an-overview-of-machine-translation/

2. **Statistische maschinelle Übersetzung (SMT)**:

   Beim SMT-Ansatz lernen die Modelle Übersetzungsmuster anhand vieler parallel übersetzter Satzpaare, ähnlich wie Menschen Sätze übersetzen. Durch die Analyse der von Menschen erstellten Übersetzungen wird ein probabilistisches Modell erzeugt, das anschließend zuvor ungesehene Sätze übersetzen kann [24].

   Zum Beispiel sieht das Modell häufig das Satzpaar: ***„Das ist mein Baum“*** (deu) = ***„This is my tree“*** (eng).

   Wenn später der englische Satz ***„This is my house“*** übersetzt werden soll, sucht das Modell nach ähnlichen Mustern und übersetzt ihn als ***„Das ist mein Haus“***. Das heißt: Anstatt Regeln manuell für die richtigen Übersetzungen zu kodieren, entscheidet das Modell auf Basis von Wahrscheinlichkeiten, welche Übersetzung am besten passt.

   Die wichtigste Ressource für den Aufbau eines hochwertigen SMT-Systems ist ein gut vorbereitetes paralleles Korpus. Das Fehlen eines solchen Korpus ist einer der häufigsten Gründe für die schlechte Übersetzungsqualität bei bestimmten Sprachpaaren [9].

3. **Neuronale maschinelle Übersetzung (NMT)**:

   Der NMT-Ansatz gilt als aktueller Stand der Technik im Bereich MT. NMT-Systeme bestehen aus komplexen, künstlichen neuronalen Netzwerken mit vielen Verarbeitungseinheiten – sie sind von der Funktionsweise des menschlichen Gehirns[2] inspiriert.

   Im Gegensatz zu den früher dominierenden SMT-Systemen, die aus mehreren getrennt optimierten Modellen bestehen, basiert NMT auf einem einzigen, integrierten neuronalen Netzwerk, das gemeinsam trainiert wird, um die Übersetzungsleistung zu maximieren [5].

   Der Encoder übernimmt die Aufgabe, einen Satz in der Quellsprache in eine numerische Darstellung umzuwandeln, und der Decoder nutzt diese abstrakte Darstellung, um schrittweise den Satz in der Zielsprache zu erzeugen, siehe Abbildung 2.1.

   Eine der leistungsfähigsten und verbreitetsten Umsetzungen dieser Architektur ist das Transformer-Modell [41]. Der Encoder besteht dabei aus einem Stapel von sechs identischen Layern (Schichten im neuronalen Netzwerk). Jeder Layer besteht aus einem

[2] https://www.rws.com/industries/legal/an-overview-of-machine-translation/
[3] https://localizejs.com/articles/exploring-neural-machine-translation-nmt/

Abbildung 2.1: NMT – Encoder und Decoder.[3]

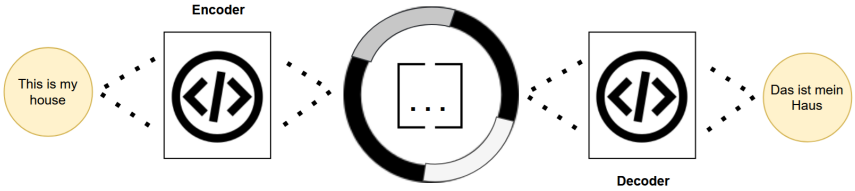

Multi-Head-Attention-Mechanismus und einem Feed-Forward-Netzwerk. Der Decoder besteht ebenfalls aus sechs Layern 2.2 und stellt eine weitere Transition von Multi-Head-Self-Attention und Feed-Forward Netzwerken dar. Zudem ist im Decoder ein dritter Multi-Head-Attention-Mechanismus eingefügt, welcher auf die Ausgabe des Encoders aufmerksam macht. Außerdem wird im Self-Attention-Mechanismus des Decoders darauf geachtet, dass jedes Wort nur von den vorhergehenden Worten abhängig ist. Alle Layer arbeiten mit einer konsistenten Anzahl von Merkmalen, die für einen konstanten Informationsfluss sorgen [41]

2.2 Herausforderungen bei Low-Resource-Sprachen

Der Fokus der heutigen NLP-Forschung liegt auf einer kleinen Anzahl weit verbreiteter Sprachen, wobei der Großteil der weltweit über 7000 Sprachen als LRLs bezeichnet werden und bisher wenig erforscht ist [25]. Dies führt dazu, dass MT für LRLs vor vielen Herausforderungen steht [11].

Ein zentrales Problem für LRLs ist die Knappheit an Trainingsdaten, insbesondere saubere Parallelkorpora [13], die für das Training moderner NMT-Modelle essenziell sind. Ein weiteres Problem ist der Mangel an grundlegenden linguistischen Werkzeugen (Tokenizer oder morphologischen Analysatoren), die für die Verarbeitung der LRLs notwendig sind [13].

Um diese Herausforderungen zu bewältigen, ist es wichtig, die Forschung für LRLs voranzutreiben. Die Unterstützung dieser Sprachen durch NLP-Tools bewahrt nicht nur das kulturelle Erbe, sondern erweitert auch den Zugang zu Wissen.

Abbildung 2.2: Architektur des Transformer-Modells [41]

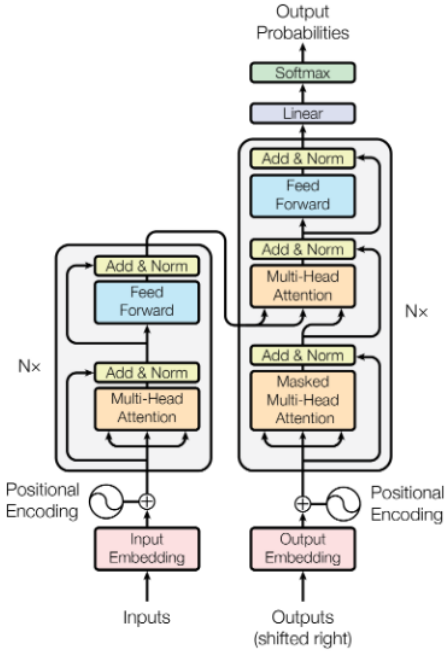

2.3 Linguistische Besonderheiten der Kobani-Variante des Kurmanji

Die linguistische bzw. morphologische Analyse spielt eine entscheidende Rollen bei der Verarbeitung natürlicher Sprache (NLP) und Computerlinguistik [1]. Für MT stellen morphologisch reiche Sprachen zusätzliche Herausforderungen dar im Vergleich zu weniger morphologisch reichen Sprachen wie Englisch [35] - vor allem bei dem Alignment (Zuordnung von Wörtern/-Phrasen zwischen Quell- und Zielsprache).
Kurdisch ist morphologisch reich und gilt als partiell agglutinierende Sprache [1] - Agglutination ist eine Methode der Wortbildung, bei der eindeutige Affix-Morpheme an ein Wurzelmorphem angehängt werden, wodurch unterschiedliche Wortformen gebildet werden [22]. Daher ist die morphologische Analyse von Kurmanji, und somit auch von Kobani, von großer Bedeutung, insbesondere für die Entwicklung leistungsfähiger MT-Systeme.

Im Vergleich zum Standard-Kurmanji (SK) [6] weist die KV potenzielle Abweichungen[4] in folgenden linguistischen Kategorien auf:

[4] https://github.com/Low-ResourceDialectology/KobaniAnalysis

2.3.1 Lexik

Die KV verwendet andere lexikalische Ausdrücke, was den Wortschatz von SK abweichen lässt, für einige Beispiele, siehe Tabelle 2.1 - Weitere Beispiele zum Wortschatzvergleich finden sich im Anhang Anhang A

Tabelle 2.1: Lexikalische Unterschiede zwischen Kurmanji und der Kobani-Variante

Kurmanji	**Kobani-Variante**	**Deutsch**
Pêlav	Sol	Schuhe
Mêr	Peya	Mann
Jê birin	Peheş kirin	Abwischen

2.3.2 Morphologie

Die KV zeigt Unterschiede in Morphologie und zwar besonders in folgenden Merkmale:

Präpositionen
In der KV werden die Endvokale von Präpositionen, die im Standard-Kurmanji auf ***-e*** enden, durch ***-a*** ersetzt, siehe Tabelle 2.2. Dies stellt eine morphologische Variation in der Bildung von Präpositionen dar.

Tabelle 2.2: Präpositionen im Kurmanji und in der Kobani-Variante.

Kurmanji	**Kobani-Variante**	**Deutsch**
bi ...* re	bi ... ra	mit
di ... de	di ... da	in
ji ... ve	ji ... va	seit / von
bi ... de	bi ... da	in, mit
bi ... ve	bi ... va	mit, mittels
di ... re	di ... ra	durch
di ... ve	di ... va	dabei, darin
ji ... de	ji ... da	aus, von
ji ... re	ji ... ra	von … her, durch (jemand)

* Zwischen dem ersten Teil der Präposition und dem zweiten Teil können beliebige Wörter (z.B. Nomen, Adjektive) stehen.

Verbdeklaration (3. Person Sg.)

Eine weitere Abweichung der KV von SK zeigt sich in der Konjugation von Verben in der dritten Person Singular. Während im SK die Konjugation mit der Endung *-e* erfolgt, wird in der KV stattdessen *-ê* verwendet, siehe Tabelle 2.3.

Tabelle 2.3: Verbkonjugation (3. Person Sg.) in der Kobani-Variante

Kurmanji	**Kobani-Variante**	**Deutsch**
Ew sêvê dixwe	Ew sêvê dixwê	Er/Sie isst den Apfel

Kopulaphrasen

Eine weitere morphologische Abweichung zeigt sich in KV bei den Kopulaphrasen (Sätzen mit Subjekt + Prädikativ + Kopulasuffix [42]). Bei sogenannten Stage-Level Predicates (vorübergehende Zustände)[5] werden geschlechtsspezifische Morpheme (*-e* für Femininum und Plural, *-î* für Maskulinum) zwischen Subjekt und Prädikat eingefügt, siehe Tabelle 2.4.

Tabelle 2.4: Kopulaphrasen in der Kobani-Variante

Kurmanji	**Kobani-Variante**	**Deutsch**
Alan li vir e.	Alan-î li vir e.	Alan ist hier.
Nalîn li vir e.	Nalîn-e li vir e.	Nalin ist hier.
Em li vir in.	Em-e li vir in.	Wir sind hier.

Ezafe-Konstruktion (Präsens)

Eine weitere interessante Abweichung zeigt sich im Präsens bei der Ezafe. Das Ezafa (auch Izafe) ist ein sprachliches Bindeelement, das ein Nomen mit einem nachfolgenden Wort verbindet [37], siehe Tabelle 2.5.

Tabelle 2.5: Ezafe-Konstruktion in der Kobani-Variante

Kurmanji	**Kobani-Variante**	**Deutsch**
Kurê min dibêje.	Kurî min dibêj*ê*.	Mein Sohn sagt.
Qîza min dibêje.	Qîzê min dibêj*ê*.	Meine Tochter sagt.
Kurên wî dibêjin.	Kurê wî dibêjin.	Seine Söhne sagen.

[5] Poster: The Ezafe as an Aspectual Marker in Copular Constructions of the Kobani Variety: Stage-Level vs. Individual-Level Predicates https://ickl-conference.org/

Zukunftsform

Auch in der Zukunftsform zeigt die KV eine Abweichung von SK. In der KV wird die Zukunftsform mithilfe von *kê* gebildet, während in SK *dê/ê* verwendet wird, siehe Tabelle 2.6.

Tabelle 2.6: Zukunftsform in der KV

Kurmanji	**Kobani-Variante**	**Deutsch**
Baran dê bibare.	Baran kê bibar*ê*.	Es wird regnen.

Nomen nach Demonstrativpronomen „ev“

In der KV, im Präsens wird das Pronomen *ev („dieser/diese/dieses“)* zu *va* umgewandelt, und das folgende Nomen bekommt dann die Endung *-a*, siehe Tabelle 2.7.

Tabelle 2.7: Nomen nach Demonstrativpronomen in der KV

Kurmanji	**Kobani-Variante**	**Deutsch**
Ev xort diçe wir.	Va xort*a* dar*ê* wir.	Dieser Junge geht hin.

In Kopulaphrasen beginnen die geschlechtsspezifischen Morpheme, wie in 2.4 erläutert, mit einem *y*, um zwei aufeinanderfolgende Vokale zu vermeiden, siehe Tabelle 2.8.

Tabelle 2.8: Nomen nach Demonstrativpronomen in Kopulaphrasen in der Kobani-Variante.

Kurmanji	**Kobani-Variante**	**Deutsch**
Ev xort li vir e.	Va xort*a* y*î* li vir e.	Dieser Junge ist hier.

2.3.3 Phonetik

Vokalverschmelzung

In der KV wird eine Abfolge aus Vokal, einem gleitenden Laut (y) und erneut einem Vokal zu einer einzigen Einheit zusammengezogen, siehe Tabelle 2.9.

Tabelle 2.9: Vokalverschmelzung in der KV (ey/êy/iyê → ê)

Kurmanji	**Kobani-Variante**	**Deutsch**
Ew ji Kobaniyê ne.	Ew-î ji Kobanê ne.	Sie sind aus Kobanî.
Ez di rêyê re çûm.	Ez di rê ra çûm.	Ich ging auf dem Weg.
Ew mamosteyê min e.	Ew mamostê min e.	Er ist mein Lehrer.

Lautveränderungen in Wörtern

Die KV zeigt bei bestimmten Wörtern phonologische Variationen durch systematische Lautwechsel, siehe Tabelle 2.10.

Tabelle 2.10: Lautveränderungen in der Kobani-Variante

Kurmanji	**Kobani-Variante**	**Deutsch**
Mêvan	Mîvan	Gast
Tûj	Toj	Scharf

2.4 Stand der Technik für kurdische MT

Als low-resource Sprachen (LRLs) weisen die kurdischen Sprachvarianten bislang nur eine geringe Abdeckung im Bereich der natürlichen Sprachverarbeitung (NLP), insbesondere im Bereich der maschinellen Übersetzung (MT), auf. Die Entwicklung von MT-Systemen für die kurdische Sprache wird durch zahlreiche Herausforderungen erschwert, darunter die große dialektale Vielfalt sowie die Verwendung unterschiedlicher Schriftsysteme [1]:

- Latein für Kurmanji
- Perso-Arabisch für Sorani
- Modifiziertes Perso-Arabisch für Hawrami

- Arabisch (in älteren Zeiten und einigen Regionen)
- Cyrillisch (in Regionen der ehemaligen Sowjet Union)

Von wenigen Ausnahmen abgesehen, gibt es bislang kaum systematische Bemühungen, kurdische MT-Modelle voranzubringen. Zu den bisher dokumentierten Arbeiten zählen unter anderem Ansätze für Kurmanji–Englisch [16, 15] sowie Sorani–Englisch [1, 4]. Auch bekannte Übersetzungsplattformen weisen Lücken und Inkonsistenzen auf. Zwar unterstützt Google Translate[6] sowohl Kurmanji als auch Sorani, die Übersetzungsqualität ist jedoch uneinheitlich und variiert stark je nach Textsorte. DeepL[7] hingegen unterstützt derzeit keine einzige kurdische Sprachvariante.

[6] translate.google.com/
[7] stand: 14.8.2025 https://www.deepl.com/de/translator

3 Datensammlung und -aufbereitung

3.1 Beschreibung und Analyse der gesammelten Daten

Bei Low-Resource-Sprachen (LRLs) wie Kurmanji stellt die Verfügbarkeit umfangreicher und hochwertiger Parallelkorpora eine der größten Herausforderungen dar. Aus diesem Grund wurde für diese Arbeit ein von Opus[1] [8] bereitgestellter Textkorpus gewählt. Dieser Korpus ist eine der wenigen öffentlich zugänglichen Ressourcen mit einer nennenswerten Anzahl an Kurmanji-Englisch-Sätzen *1,015,966*. Dieser Textkorpus trägt den Namen NLLB (No Language Left Behind)[2] [40], wurde von Meta AI entwickelt und über AllenAI auf HuggingFace[3] bereitgestellt.

Um einige Information über diesen umfangreichen Korpus zu gewinnen, wurde eine Analyse durchgeführt. Die Analyse der Daten ergibt eine mittlere Satzlänge von *10,04* Wörtern für Kurmanji und *10,64* für Englisch mit einem Längenverhältnis von *1,12*, was eine ausgewogene Datenbasis für MT bestätigt, siehe Tabelle 3.1.

Tabelle 3.1: Statistiken des NLLB Kurmanji-Englisch-Datensatzes

Metrik	Kurmanji	Englisch
Mittlere Satzlänge (Wörter)	10,04	10,64
Standardabweichung (Wörter)	5,96	6,19
Min. Satzlänge (Wörter)	2	1
Max. Satzlänge (Wörter)	107	98
Mittlere Satzlänge (Zeichen)	53,67	58,18
Standardabweichung (Zeichen)	31,92	35,18
Min. Satzlänge (Zeichen)	10	8
Max. Satzlänge (Zeichen)	498	498
Anzahl Satzpaare	1.015.966	
Längenverhältnis	1,12	

[1] https://opus.nlpl.eu/results/en&ku-Latn/corpus-result-table
[2] https://ai.meta.com/research/no-language-left-behind/de/
[3] https://huggingface.co/datasets/allenai/nllb

3.2 Datenbereinigung und Vorverarbeitung

Während der Analyse und beim Durchsehen der Rohdaten zeigte sich, dass bei vieler Satzpaaren unerwünschte Elemente wie HTML-Tags oder Währungsangaben inkonsistent sind, siehe Tabelle 3.2.

Tabelle 3.2: Beispiele für Fehlerarten in Satzpaaren

Fehlerart	Englisch	Kurmanji
Währungsinkonsistenz	Many people will save $150 or more right off the bat!	Divê € 100 niha ji bo ku heqê herî zêde bigire!
Unerwünschte HTML-Tags	I am not saying that there is no God (I myself am an Orthodox Christian), and neither is anyone else, unless they are omnipotent (and in that case, they would be God).	Lê ez tu care jî nabim şirîkê xeletiyê. Xazî (Tevgera Yekitiya Îslamî): Xwedê piştevanê hemû mazlûman bibe.

Um den NLLB-Textkorpus für das Übersetzungssystem nutzbar zu machen, wurden eine Reihe von Vorverarbeitungs- und Filterungsschritten mit dem Tool OpusCleaner[4] durchgeführt. OpusCleaner ist ein Open-Source-Toolkit [8], das eine grafische Oberfläche zur Verfügung stellt, eine Pipeline-basierte Verarbeitung von parallelen Korpusdaten ermöglicht und eine Vielzahl von Filtern bietet, um die Datenqualität zu optimieren.

Die Verarbeitung der Daten umfasste mehrere Schritte: Reinigung, Normalisierung und Strukturierung. Ein Beispiel ist der *num_mismatch*-Filter[5], der Satzpaare entfernt, in denen die Zahlen nicht übereinstimmen, siehe Tabelle 3.3 [6].

Tabelle 3.3: Filter in OpusCleaner mit Beispielen für Englisch–Kurmanji

Filtername	Zweck	Einstellung	Gefiltertes Paar / gefixte / betroffene
num_mismatch	Zahlenvergleich Quelle/Ziel	default	**en**: On March 14, she went to her aunt's house and went missing. **ku**: Di 16 ê îlonê de li mala mamê xwe ji qata çaremîn a malê avêt û xwest xwe bikuje.

[4] https://github.com/hplt-project/OpusCleaner?tab=readme-ov-file

[5] Die vollständige Liste aller verwendeten Filter befindet sich im A.1. Diese kann in OpusCleaner direkt angewendet werden, um die Daten der Arbeit exakt zu reproduzieren.

[6] Eine Auswahl gefilterter Satzpaare nach Anwendung der Filter befindet sich im Unterabschnitt A.1.1

Filtername	Zweck	Einstellung	Gefiltertes Paar / gefixte / betroffene
opus.RegExpSub	Ersetzt Text mithilfe von regulären Ausdrücken (Pattern → Replacement)	Pattern: þ → ş Pattern: ž → ş Pattern: ź → ê	**vorher**: Dema artêþ tê gotin þer tê bîra mirov. **nachher**: Dema artêş tê gotin şer tê bîra mirov.
normalize_white-space	Entfernt überflüssige Leerzeichen und Tabs	default	**vorher**: Contact us___today_ for more information. **nachher**: Contact us today for more information.
opus.HtmlTagFilter	Entfernt HTML-Tags aus Segmenten	default	**vorher**: Lê ez tu care jî nabim şirîkê xeletiyê. Xazî (Tevgera Yekitiya Îslamî): Xwedê piştevanê hemû mazlûman bibe. **nachher**: Lê ez tu care jî nabim şirîkê xeletiyê. Xazî (Tevgera Yekitiya Îslamî): Xwedê piştevanê hemû mazlûman bibe.

Obwohl OpusCleaner umfangreiche Filtermöglichkeiten anbietet, bleiben einige fehlerhafte Satzpaare bestehen. Dazu gehören bspw. Enconding-Fehler und Steuerzeichen wie `\r\n\r\n`. Diese wurden anschließend mit eigenen Skripten behandelt, siehe Tabelle 3.4.

Tabelle 3.4: Steuerzeichen und Kodierungsfehler im Kurmanji-Korpus

Englisch	Kurmanji
Tech Mahindra has set up a state-of-the-art MSTV Lab at its facility in India	Malper CÃ®han DÃa hikÃ"meteke Ã®slamÃ® li cÃ®hanÃa were damezrandin
Once again I'm reminded that I'm not in Northern Germany anymore.	Yek-du ez ê jî êdî qet rexne nekim.`\r\n\r\n`Silavên Bakurî.

3.3 Herausforderungen bei der Datenknappheit

Obwohl Opus sich mit dem NLLB-Korpus als eines der größten Parallelkorpora für Kurmanji-Englisch präsentiert, erweist sich die tatsächliche Nutzbarkeit dieser Daten bei genauerer Analyse als eingeschränkt. Das liegt daran, dass viele der Sätze fehlerhaft, unstimmig oder inkonsistent sind.

Nach der Vorverarbeitung und Bereinigung der Daten durch die Nutzung der OpusCleaner-Filter wurde festgestellt, dass ein erheblicher Anteil der Sätze unnutzbar war. Die ursprüngliche Datenmenge von **1.015.966** Satzpaaren verringerte sich auf **823.001** Satzpaare. Diese Reduktion verdeutlicht, dass trotz einer großen Datenbasis nur ein Teil davon nutzbar sein kann.

4 Methodik

4.1 Regelbasierter Ansatz

Nachdem die Kurmanji-Daten gefiltert und gesäubert wurden (siehe Abschnitt 3.2), werden sie nun zu synthetischen Kobani-Daten transformiert. Diese Transformation erfolgt mithilfe des regelbasierten Ansatzes, siehe Abbildung 1.1. Dabei kommen die im Abschnitt 2.3 identifizierten linguistischen Regeln sowie das Wörterbuch (Kurmanji - Kobani)[1] zum Einsatz.

4.2 Linguistische Regeln und Wörterbuch

Für die linguistische Transformation wurde ein Part-of-Speech (PoS) Tagger verwendet, der die morphologischen und syntaktischen Besonderheiten aus den Kurmanji-Daten extrahiert. Das Stanza-Projekt [34][2] stellt die Infrastruktur für das Training von PoS-Tagger zur Verfügung. Eine wichtige Grundlage für das Training des Kurmanji-PoS-Taggers ist die von [12] erstellte UD (Universal Dependencies - ein standardisiertes Format zur linguistischen Annotation) Kurmanji treebank, welche den ersten Schritt für Northern Kurdish (NK) PoS-Tagging ermöglichte. Darauf aufbauend, haben [26] verschiedene Ansätze verfolgt, um einen noch besseren PoS-Tagger für NK zu trainieren. Für die Perturbation in dieser Arbeit kommt die Variante **NK-XLMR** zum Einsatz; die dafür berichteten Leistungswerte (Genauigkeit: 0.87, F1-Score: 0.77) entstammen der Publikation der Modellautoren. Obwohl dieser neue PoS-Tagger eine sehr gute Performance bezüglich der Identifikation von Ezafe an den Tag legte, zeigten sich weiterhin Limitationen, vor allem bei der Identifikation von Adverben, welche eine Fehlerrate von *0.73* aufwies.

Neben dem PoS-Tagger wurde ein selbst erstelltes zweisprachiges Wörterbuch verwendet, das für jedes Kurmanji-Wort das entsprechende Kobani-Wort enthält, siehe Tabelle 2.1. Dieses

[1] https://github.com/RamanAhmad/kobani-mt/blob/main/data/kobani_kurmanji_dictionary_sorted.json
[2] https://stanza.stanford.edu/

Wörterbuch entstand über einen längeren Zeitraum, in dem die Kobani-Wörter systematisch gesammelt wurden.

4.3 Implementierung des regelbasierten Perturbationssystems

Das Perturbationssystem basiert auf zwei zentralen Komponenten: zum einen linguistische Regeln, zum anderen ein Wörterbuch, siehe Abbildung 1.1. Dieser Abschnitt beschreibt diese beiden Komponenten im Detail.

4.3.1 Linguistische Regeln

Die im Abschnitt 2.3 beschriebenen linguistischen Reglen wurden umgesetzt, indem Kurmanji-Daten mithilfe von PoS und Python-Skripten perturbiert wurden. Die Python-Skripte bilden in Kombination mit PoS-Informationen eine wiederverwendbare Pipline, die die Perturbationen sequenziell und automatisch auf beliebige Textdaten durchführt. Ein Beispiel ist die Perturbation des Verbs **diçe** („geht“ - dritte Person Singular) zu **dare** und dann zu **darê**, siehe Tabelle 4.3.

Von den 10 identifizierten Regeln, konnten 8 erfolgreich für die Erstellung synthetischer Daten umgesetzt werden, siehe Tabelle 4.1. Die Kopulaphrasenregel in Tabelle 2.3.2 und damit auch “Nomen nach Demonstrativpronomen in Kopulaphrasen” in Tabelle 2.8 erfordern einen solchen Aufwand, dass er den Rahmen dieser Arbeit übersteigt. Zwar kann PoS die syntaktischen Eigenschaften identifizieren [3], nicht jedoch semantische Merkmale wie Stage-Level oder Individual-Level Predicates, was die Implementierung dieser Regeln erschwert. Für zukünftige Folgearbeiten werden die nötigen Schritte im Folgenden kurz beschrieben:

1. **Syntaxanalyse:** Die Kopulaphrasen müssen identifiziert werden. Hierfür kann das Stanza-Tool mit dem Modell *„UD_Northern_Kurdish“*[3] verwendet werden.

2. **Identifizierung temporärer Adjektive:** Nachdem die Kopulaphrasen erkannt wurden, müssen die Adjektive identifiziert werden, die temporäre Zustände beschreiben. Auch dies kann mit dem UD-Tool erfolgen.

3. **Numeruslogik:** Der Numerus des Subjekts muss erkannt werden, da sich die Ezafe-Endung je nach Subjekt verändert. Dies kann entweder mithilfe der Deklaration des **Bûn**-Verbs *(„sein“)* oder mit dem Apertium-Tool[4] erfolgen.

[3] https://github.com/UniversalDependencies/UD_Northern_Kurdish-Kurmanji
[4] https://github.com/apertium/apertium-kmr?tab=readme-ov-file

4. **Anwendung der Ezafe-Regeln:** Das Subjekt erhält die Endung *-e*, wenn es sich um eine feminine Singular-Person oder um einen Plural handelt, die Endung *î*, wenn das Subjekt maskulin ist. Siehe Tabelle 2.4

Tabelle 4.1: Statistik der regelbasierten Vorverarbeitung

Schritt	**Änderungen**	**Anteil (%)**
Gesamtsätze	814.858	100,00
Gesamtwörter	5.319.062	
Geänderte Sätze	561.944	68,96
Gesamt geänderte Wörter	936.295	17,60
Durchschnittlich geänderte Wörter pro verändertem Satz	1,15	

4.3.2 Wörterbuch

Das in Abschnitt 4.2 beschriebene Kurmanji-Kobani-Wörterbuch wurde hier verwendet, um die Perturbation auf der Wortebene durchzuführen. Die Umwandlung von Kurmanji-Wörtern in Kobani-Wörter funktioniert durch die Ersetzung lexikographischer Einheiten bei den Wörtern, die mit einem Konsonanten enden oder Adjektive bzw. Adverbien sind (siehe Tabelle 4.3). Bei der Perturbation der Nomen, die mit einem Vokal enden, muss die Vokalverschmelzungsregel in Unterabschnitt 2.3.3 betrachtet werden. Der Grund hierfür sind die verschiedenen Suffixe, die die Nomen in unterschiedlichen grammatikalischen Fällen erhalten. In diesem Fall muss ein zusätzlicher Bindlaut eingeführt werden, z. B. **Zarokek** („ein Kind“, *Zariyak* erhält ein „*y*“ – siehe Tabelle 4.2).

Tabelle 4.3: Anwendung von Regeln und Wörterbuch auf einen Kurmanji-Satz.

Regel / Wörterbuch	**Satz**
	Her ku diçe tirs û kîn bi hev re mezintir dibin. (Je weiter es geht, desto größer werden Angst und Hass zusammen.) Her (SCONJ) ku (SCONJ) diçe (VERB) tirs (NOUN) û (CCONJ) kîn (NOUN) bi (ADP) hev (PRON) re (ADP) mezintir (ADJ) di (ADP) bin (NOUN) . (PUNCT)
Preposition	Her ku diçe tirs û kîn bi hev ra mezintir dibin.
Wörterbuch	Her ku dare tirs û buxz bi hev ra mezintir dibin.
Dritte Person	Her ku darê tirs û buxz bi hev ra mezintir dibin.

Tabelle 4.2: Nomendeklination nach Kasus bei der regelbasierten Perturbation von Kurmanji- zu Kobani-Wörtern

Deutsch	Ich kenne jene Kinder.
Kurmanji	Ez wan zarokan nas dikim.
Kobani	Ez wan zariyan nas dikim.
Deutsch	Und viele haben ihre Kinder nach ihr benannt.
Kurmanji	Û gelekan navê wê li zarokên xwe kirine.
Kobani	Û gelekan navê wê li zarê xwe kirine.
Deutsch	Er war das letzte Kind eines Geschäftsmannes.
Kurmanji	Zarokê dawîn ê karsazekî bû.
Kobani	Zarê talê ê karsazekî bû.
Deutsch	In jener Gruppe befindet sich auch ein Kind.
Kurmanji	Di nav wê komê de zarokek jî heye.
Kobani	Di nav wê komê da zariyak jî heye.
Deutsch	Ich möchte ein Kind haben.
Kurmanji	Ez dixwazim ku zarokekî min bibe.
Kobani	Ez dixwazim ku zariyakî min bibê.

Stammform (Kurmanji) Stammform (Kobani) Bindelaut Pluralmarker Ezafe Indefinit-Suffix

4.4 Transfer-Learning-Ansatz

Transfer Learning (TL) in MT ist ein Ansatz, bei dem das Wissen von einem vortrainierten Modell als Grundlage für das Training eines neuen Modells verwendet wird [18, 45]. Dieser Ansatz ermöglicht es, die Leistungsfähigkeit von dem neuen Modell zu verbessern, indem das Wissen des vortrainierten Modells beibehalten wird. Dies reduziert den Trainingsaufwand, im Gegensatz zum traditionellen Lernen, bei dem ein Modell von Grund auf neu gebaut und trainiert werden muss, siehe Abbildung 4.1.

4.5 Auswahl des vortrainierten Modells

Für diese Arbeit wurde das von Meta entwickelte Übersetzungsmodell NLLB-Base-Modell (No Language Left Behind) gewählt. Das NLLB-Base-Modell deckt 200 Sprachen ab, darunter viele LRLs, für die geeignete Datenaufbereitung genutzt wurde [40]. Das NLLB-Base-Modell unterschtützt Kurmanji und hat zudem im PARME-Projekt [2], das sich mit kurdischen Dialekten und anderen LRLs beschäftigt, gute Ergebnisse erzielt. Neben dem NLLB-Base-Modell wurden noch andere vortrainierte Modelle betrachtet:

Abbildung 4.1: Traditionelles Lernen in der maschinellen Übersetzung im Vergleich zum Transfer-Learning. Inspiriert von [28].

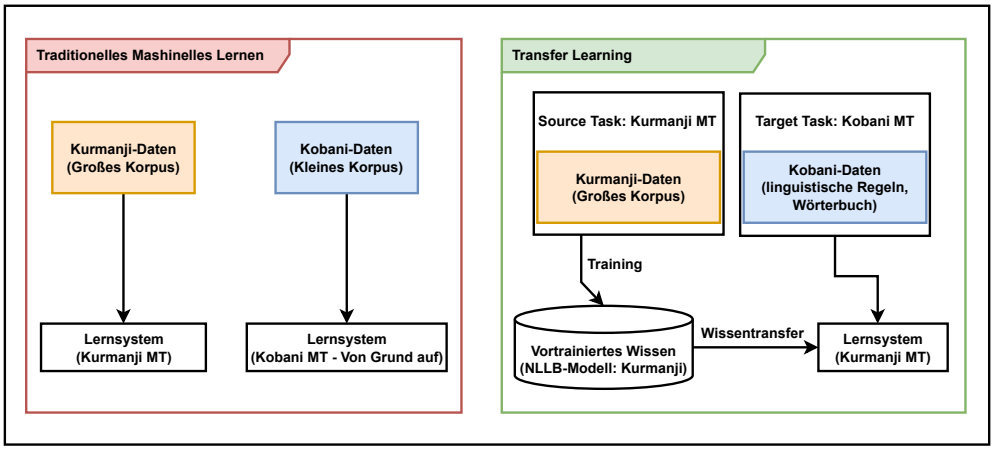

- Modelle, die kein Kurmanji enthielten wie *mBART-50* [39] und *M2M-100* [10].
- Modelle, die nicht für Finetuning freigegeben sind wie *Google Translate*[5].

Aus diesen Gründen hat es nur das NLLB-Base-Modell geschafft, in die Experimente zu kommen.

4.6 Fine-tuning auf Kobani-Daten

Das Fine-tuning des NLLB-Base-Modells basierte auf Transfer-Learning mit einem seq2seq-basierten (sequence-to-sequence) Lernverfahren [38]. Das seq2seq-Lernverfahren ist ein Modelltyp in MT, der aus einem Encoder und einem Decoder besteht und eine Eingabesequenz in eine Ausgabesequenz umwandelt. Das Fine-tuning-Verfahren umfasste folgende Schritte:

1. Der im Abschnitt 4.3 erstellte parallele Textkorpus aus englischen und synthetischen kobanischen Sätzen wurde als Trainingsdaten verwendet.
2. Der Tokenizer des Basismodells wurde erweitert:
    - Um kobanispezifische Subwords zu extrahieren, wurde ein temporäres SentencePiece-Modell auf den Kobani-Daten trainiert.

[5] https://translate.google.com

- Die erlernten Tokens wurden in den NLLB-200-Tokenizer integriert.
- **kob_Latn** wurde als Spezialtoken hinzugefügt.

3. Die bestehenden Embeddings von **kmr_Latn** wurden als Initialisierung für **kob_Latn** übernommen.
4. Das Verfahren wurde mit dem Hugging-Face-Trainer durchgeführt. Alle Hyperparameter sind im Abschnitt A.2 beschrieben.

4.7 Kombination von regelbasiertem Ansatz und Transfer-Learning

Durch die Kombination von RBA in Abschnitt 4.1 und TL in Abschnitt 4.4 entstand ein funktionales fine-tuned MT-Modell für die KV, siehe Abbildung 1.1. Der RBA erzeugte aus den Kurmanji-Daten synthetische Kobani-Sätze mittels PoS-Tagging, linguistischer Regeln und einem Kurmanji-Kobani-Wörterbuch. TL hingegen nutzte diesen synthetischen Korpus, um das vortrainierte NLLB-Base-Modell durch Fine-tuning auf die KV zu spezialisieren. Hierbei wurde der Seq2SeqTrainer[6] der Hugging-Face-Transformers-Bibliothek [43] verwendet. Der Seq2SeqTrainer stellt die Trainingslogik für Encoder-Decoder-Modelle bereit, sodass das Fine-tuning des Modells ohne Änderung der Modellarchitektur ermöglicht wird. Beide Ansätze ergänzten sich ideal und lieferten am Ende ein reproduzierbares, robustes MT-System für die KV.

[6] https://huggingface.co/docs/transformers/main_classes/trainer

5 Evaluation

Die Evaluation in MT ist ein Prozess, mit dem die Übersetzungsqualität gemessen wird. In dieser Arbeit wurde ein fester Testdatensatz benutzt und dabei die Ergebnisse des Basis-NLLB-Base-Modells mit dem fine-tuned Modell verglichen. In diesem Kapitel werden die Ergebnisse des fine-tuned NLLB-Base-Modells mit verschiedenen Metriken bewertet. Dies umfasst automatisierte objektive Metriken (BLEU, chrF++, TER). Eine menschliche Evaluation wurde in dieser Arbeit aufgrund des hohen Zeitaufwands und der Kosten [29] nicht durchgeführt. Um zukünftig eine subjektive Bewertung der Übersetzungsqualität des fine-tuned NLLB-Base-Modells zu bekommen, muss eine menschliche Evaluation durchgeführt werden. Diese kann zum Beispiel mithilfe des Potato-Tools [31] umgesetzt werden. Potato ist ein Open-Source-Annotationswerkzeug und dient dazu, Daten für MT manuell zu annotieren.

5.1 Automatische Metriken

Für einen objektiven und reproduzierbaren Vergleich der Übersetzungsqualität zwischen dem NLLB-Base-Modell und dem fine-tuned Modell, wurden die folgenden etablierten Metriken verwendet:

- **BLEU** [29] misst die Übereinstimmungen von n-Grammen (Wortsequenzen) zwischen der Modellübersetzung und der Standard-Übersetzung, die als ideal angenommen wird.
- **chrF++** [33] bewertet die Zeichenähnlichkeiten und ist besonders geeignet für morphologisch reiche Sprachen wie Kurmanji.
- **TER** [36] misst die minimale Anzahl notwendiger Bearbeitungen (Edits), um eine Übersetzung in die Referenzübersetzung zu überführen.

Diese Metriken wurden so gewählt, dass unterschiedliche Aspekte der Übersetzungsqualität abgedeckt werde, und sie sind als gängiger Standard in der Evaluation von MT etabliert.

5.2 Durchführung der Experimente

Das Fine-tuning wurde wie im Abschnitt 4.6 beschriebenen Verfahren durchgeführt. Insgesamt fanden zwei separate Fine-tuning-Experimente statt, in denen das NLLB-Base-Modell einmal für die Übersetzungsrichtung **Kobani** → **Englisch** und einmal für die Übersetungsrichtung **Englisch** → **Kobani** fine-tuned wurde (siehe Tabelle 5.1). Das Fine-tuning wurde in den durchgeführten Experimenten bewusst unidirektional trainiert, um eine isolierte Analyse der Effekte sicherzustellen. Die beiden fine-tuned Modelle (**nllb-200-distilled-600-eng-to-kob_Latn**[1] und **nllb-200-distilled-kob_Latn-to-eng**[2]) wurden mit denselben Trainingsdaten (siehe Kapitel 3) und Hyperparametern (siehe Abschnitt A.2) fine-tuned und sind auf Hugging Face[3] verfügbar.

Tabelle 5.1: Übersetzungsqualität des NLLB-Base-Modells und des fine-getunten Modells

Modelltyp	**Richtung**	**BLEU**	**chrF++**	**TER**
NLLB-200-distilled-600M (Base)	Englisch → Kobani*	4.48	24.68	102.82
	Englisch → Kurmanji	5.79	25.93	99.52
	Kobani* → Englisch	6.83	22.90	139.20
	Kurmanji → Englisch	9.18	26.90	90.20
Fine-tuned NLLB-200-distilled-600M	Englisch → Kobani	5.77	20.20	124.59
	Englisch → Kurmanji	4.58	19.38	125.35
	Kobani → Englisch	**8.65**	**24.83**	**98.45**
	Kurmanji → Englisch	5.04	23.29	138.64

* Das ursprüngliche NLLB-Base-Modell unterstützt die Sprach-ID „kob_Latn“ nicht. Hier wurde „kmr_Latn“ als Sprach-ID verwendet.

5.3 Ergebnisse des NLLB-Base-Modells und des fine-tuned Modells

Um die Übersetzungsqualität des vortrainierten NLLB-Base-Modells zu bewerten, wurde das Basismodell mit dem fine-tuned Modell verglichen. Die Evaluation wurde auf einem festgelegten Testdatensatz in den vier Übersetzungsrichtungen durchgeführt (siehe Tabelle 5.1). Da das

[1] https://huggingface.co/RamanAhmad/nllb-distilled-600m-eng-to-kob_Latn
[2] https://huggingface.co/RamanAhmad/nllb-distilled-600m-kob_Latn-to-eng
[3] https://huggingface.co/

Basismodell die KV vor dem Fine-tuning-Verfahren (Sprach-ID **kob_Latn** ist nicht vorhanden) nicht unterstützt, wurden die Kobani-Daten (die kurmanji-perturbierten Daten) mit der Sprach-ID **kmr_Latn** (Kurmanji) versehen.

Die Ergebnisse der Experimente zeigen folgende wichtige Beobachtungen:

- **Das Basismodell** zeigt für die Übersetzungsrichtung **Kurmanji** → **Englisch** die beste Leistung **(BLEU 9.18)**, da das NLLB-Base-Modell ursprünglich Kurmanji unterstützt. Die Übersetzungsrichtung **Kobani*** → **Englisch** weist hingegen sehr hohe TER-Werte auf **(139.20)**. Dies deutet auf eine hohe lexikalische Abweichung hin, die durch die Perturbation zustande kommt (siehe Abbildung 5.1).

- **Das fine-tuned Modell** führt zu einer deutlichen Verbesserung **(BLEU 8.65)** für die Richtung **Kobani** → **Englisch** im Vergleich zum Basismodell für die gleiche Richtung (siehe Abbildung 5.2).

- Im Gegensatz zur Übersetzungsrichtung **Kobani** → **Englisch** zeigt die Übersetzungsrichtung **Kurmanji** → **Englisch** des fine-tuned Modells einen deutlichen Rückgang bei allen drei Metriken im Vergleich zum Basismodell. Als mögliche Ursache kommt hierfür ***catastrophic forgetting*** [21] infrage, bei dem das Training auf den Kobani-Daten das gelernte Kurmanji-Wissen überschrieben hat (siehe Abbildung 5.3).

Insgesamt lässt sich sagen, dass das Fine-tuning die Übersetzungsqualität für die Übersetzungsrichtung **Kobani** → **Englisch** deutlich verbessert hat, während die Übersetzungsrichtung **Kurmanji** → **Englisch** einen klaren Qualitätsverlust zeigt. Dies bestätigt, dass die Kobani-Daten einen deutlichen Einfluss auf das Verfahren haben.

5.4 Analyse und Diskussion der Übersetzungsergebnisse

Um die Übersetzungsqualität (siehe Abschnitt 5.2) qualitativ zu analysieren, wurden 60 Übersetzungen aus den vom Modell erzeugte Hypothesen zufällig ausgewählt (siehe Tabelle A.2) und den jeweiligen Referenzübersetzungen gegenübergestellt. Die in Tabelle 5.2 dargestellten Übersetzungen stellen eine Auswahl von sechs Sätzen dar. Die vollständige Tabelle der Übersetzungsbeispiele ist im Anhang in der Tabelle A.2 zu finden. Diese Übersetzungen sind anhand der Zeichen-Ähnlichkeit zwischen Referenzübersetzung und Modellhypothese in drei Kategorien eingeteilt: **sehr hohe Ähnlichkeit** (80–100 %), **mittlere Ähnlichkeit** (40–60 %) und **sehr niedrige Ähnlichkeit** (0–20 %).

Abbildung 5.1: TER-Vergleich (niedriger ist besser): Base vs. Fine-tuned NLLB-200-distilled-600M

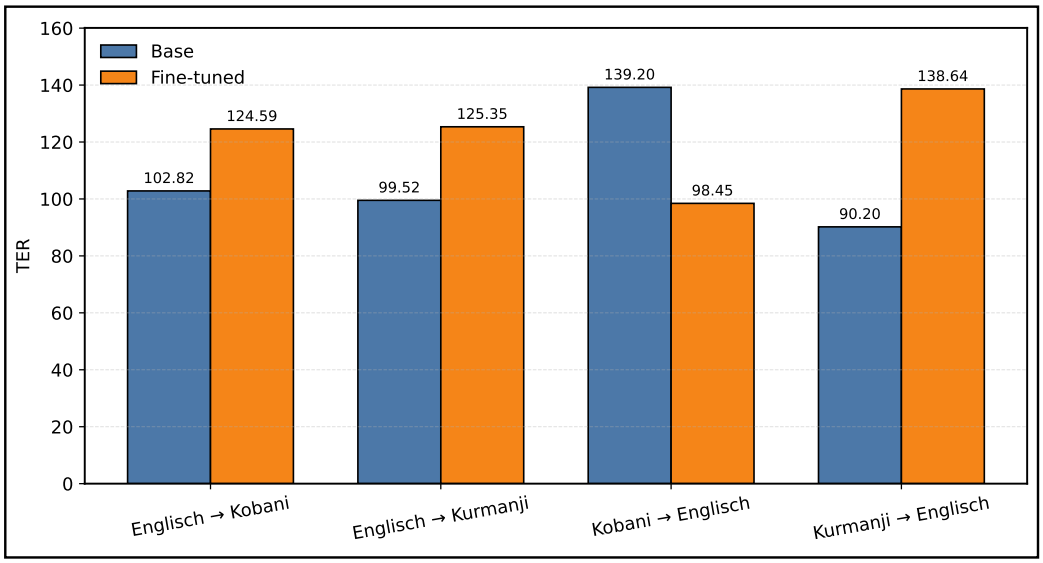

Abbildung 5.2: BLEU-Vergleich: Base vs. Fine-tuned NLLB-200-distilled-600M

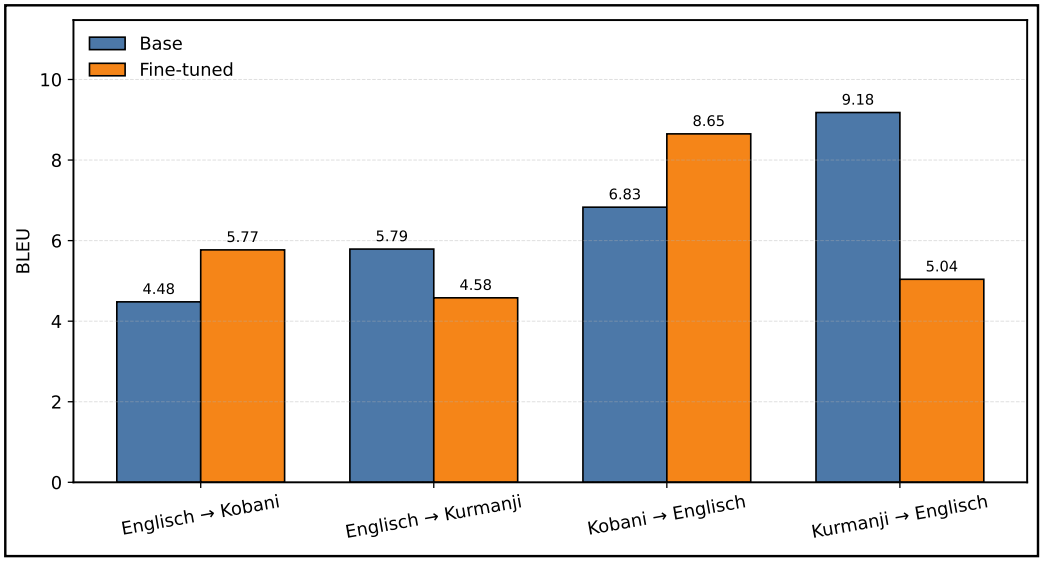

Abbildung 5.3: chrf++-Vergleich: Base vs. Fine-tuned NLLB-200-distilled-600M

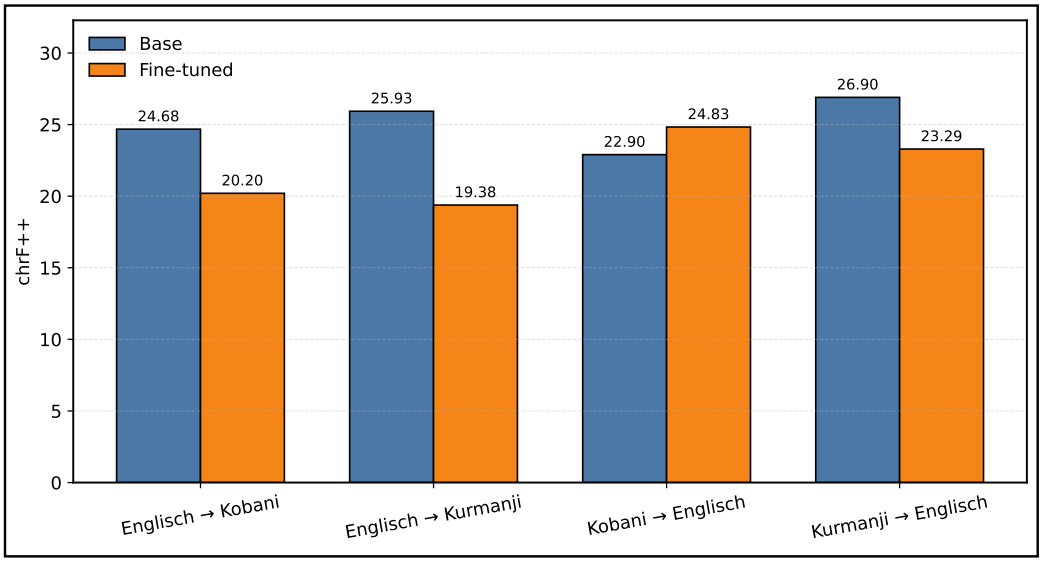

Auf Basis dieser Kategorisierung ergeben sich folgende Beobachtungen:

- Bei Übersetzungen mit **sehr hoher Ähnlichkeit** stimmen die Hypothesen vollständig mit den Referenzübersetzungen überein (siehe Satz-IDs 1 und 2 in Tabelle 5.2). Sowohl Wörter aus dem selbst erstellten Kobani-spezifischen Wörterbuch, z. B. **Merî** („*Mensch*", Satz-ID 6 in Tabelle A.2) als auch durch linguistische Regeln veränderte Daten, z. B. **bik*ê*** („*macht*", Satz-ID 2 in Tabelle A.2) werden korrekt wiedergegeben. Dies zeigt, dass das fine-tuned Modell bestimmte lexikalische Besonderheiten und morphologische Strukturen erlernt hat.

- In der Kategorie **mittlerer Ähnlichkeit** treten deutliche Abweichungen auf, jedoch kann die zentrale Bedeutung der Übersetzungen noch erkannt werden. In einigen Sätzen werden Satzteile teilweise ausgelassen oder gleiche Wörter wiederholt (siehe Satz-IDs 23 und 30 in Tabelle A.2). Diese Ergebnisse zeigen, dass die fine-tuned Modelle zwar den semantischen Kern erfassen, jedoch nicht immer eine präzise Formulierung liefern.

- Bei **sehr niedriger Ähnlichkeit** unterscheiden sich die Referenzübersetzung und die Modellhypothese. Diese Unterscheidung ist sowohl inhaltlich als auch formal. In dieser Kategorie ist der Einfluss von englischen Begriffen sowie Sprachmischungen deutlich zu sehen (siehe Satz-IDs von 37 bis 54 in Tabelle A.2). Besonders auffällig sind die unzu-

sammenhängenden Satzstrukturen und teilweise vollständig halluzierte Ausgaben (siehe Tabelle A.2), was ein bekanntes Problem neuronaler MT-Sytemen ist [44].

Zusammenfassend lässt sich sagen, dass das Fine-tuning des NLLB-Base-Modells für die KV bei hoher Ähnlichkeit sehr zuverlässige Ergebnisse liefert. Dies betrifft sowohl die Reproduktion der kobani-spezifischen Lexik (siehe Unterabschnitt 2.3.1) als auch einige morphologische Besonderheiten (siehe Unterabschnitt 2.3.2 und Unterabschnitt 2.3.3). Allerdings zeigen sich auch Schwächen, insbesondere bei der Realisierung des Demonstrativpronomens **„va“** (*„Dieses“* siehe Satz-ID 36 in Tabelle A.2). Dies könnte daran liegen, dass die trainierten Daten solche Konstruktionen nicht in ausreichendem Maße enthalten.

Tabelle 5.2: Repräsentative Übersetzungsbeispiele mit Referenz und Modellhypothese

Satz-ID	Ähnl. (%)	Referenz und Hypothese
		Sehr hohe Ähnlichkeit
1	100 %	**Referenz**: 20 deqeyan da herî kêm. **Hypothese**: 20 deqeyan da herî kêm.
2	100 %	**Referenz**: navê we yek e. **Hypothese**: navê we yek e.
		Mittlere Ähnlichkeit
3	54.5 %	**Referenz**: Ez çi bibêjim biracan? **Hypothese**:em çi bêjin biracan.
4	54.8 %	**Referenz**: Di sala 2000an da ez vegerîyam. **Hypothese**: di sala 2000an da dest pê kir.
		Niedrige Ähnlichkeit
5	9.9 %	**Referenz**: Guhanber , herweha em bi xwe jî pêre, di nav vê komê da ne, weke ko hevîrtirşekî adetî bin. **Hypothese**: ya organîzekirinê ye, lê belê va organîzekirinê ye, di vê çarçovê da, em li hev kom dibin.
6	9.9 %	**Referenz**: Va komkujî tenê çirûskek ji bi hezaran komkujê ku dagirkeran li Kurdistanê pêk anînê ye. **Hypothese**: ne bi tenê nûçegihanîna ku dinya ji destê din hat ji hezaran tije kampên penabera li Sudan.

6 Fazit und Ausblick

6.1 Zusammenfassung der wichtigsten Erkenntnisse

In dieser Arbeit wurde für die KV das vortrainierte NLLB-Base-Modell fine-tuned und evaluiert. Das gesamte Verfahren gliedert sich in drei Hauptblöcke:

1. **Erzeugung synthetischer Daten**: Als Grundlage wurden der von Opus bereitgestellte Textkorpus (siehe Kapitel 3) verwendet. Diese Daten wurden zunächst mit OpusCleaner[1] und selbst erstellten Skripten gefiltert und bereinigt. Danach wurden die bereinigten Daten mithilfe eines selbst entwickelten regelbasiertern Perturbationssystems (sieh Abschnitt 4.1) unter Verwendung linguistischer Regeln und eines selbst erstelltes Wörterbuchs in synthetische Kobani-Daten umgewandelt.

2. **Fine-Tuning des NLLB-Base-Modells**: Das vortrainierte NLLB-Base-Modell wurde mittels Transfer Learning auf den synthetischen Kobani-Daten fine-tuned (siehe Abschnitt 4.4).

3. **Evaluierung**: Die Bewertung erfolgte anhand automatischer Metriken (BLEU, chrF++ und TER). Anschließend wurde eine qualitative Analyse anhand 60 zufällig ausgewählten Übersetzungsbeispielen durchgeführt (siehe Abschnitt 5.3).

Die Ergebnisse des finetuned NLLB-Base-Modell, insbsondere für die Übersetzungsrichtung **Kobani** → **Englisch** zeigen eine Verbesserung gegenüber dem NLLB-Base-Modell in allen Metriken (Siehe Tabelle 5.1). Das fine-tuned NLLB-Base-Modell zeigt besonders starke Fortschritte bei bestimmten morphologischen und lexikalischen Besonderheiten der KV (siehe Abschnitt 5.4). Insgesamt lässt sich sagen, dass Transfer Learning auf Basis eines vortrainierten Modells einen validen Ansatz zur Anpassung an sprachliche Varianten des Nordkurdischen bietet.

[1] https://github.com/hplt-project/OpusCleaner

6.2 Beantwortung der Forschungsfragen

In dieser Arbeit wurden die in Kapitel 1 formulierte Forschungsfragen untersucht. Diese Fragen werden basierend auf den Ergebnissen der Datenperturbatierung, des Fine-tunings und der Evaluation beantwortet.

6.2.1 Forschungsfrage 1

Inwiefern kann ein regelbasiertes Perturbationssystem für die maschinelle Übersetzung zwischen Englisch und Kobani-Variante entwickelt werden, das auf einem Wörterbuch aufbaut und linguistische Merkmale systematisch verwendet, um die Datenknappheit zu überwinden?

Es konnte gezeigt werden, dass ein regelbasiertes Perturbationssystem aus einem Wörterbuch und linguistischer Regeln effektiv eingesetzt werden kann, um aus dem über Opus bereitgestellten Textkorpus (siehe Kapitel 3) große Mengen synthetischer paralleler Kobani-Englisch-Daten zu erzeugen (siehe Abschnitt 4.3 und Tabelle 4.1).
Fazit zu Forschungsfrage 1: Das regelbasierte Perturbationssystem kann die lexikalische Substitution (Wörterbuch), morphologische Umwandlung (u. a. Verbkonjugationen in der 3. Person Singular) und die phonologischen Anpassungen (Vokalverschmelzung *ey/êy/iyê* $\rightarrow$ *ê*) gut umsetzen. Idiomatische und stark kontextabhängige Ausdrücke wurden im Rahmen dieses regelbasierten Perturbationssystems nicht berücksichtigt und stellen somit eine Einschränkung dar.

6.2.2 Forschungsfrage 2

Wie gut lässt sich das vortrainierte Übersetzungsmodell (NLLB-200-distilled-600M-Modell [40]), das bereits Englisch-Kurmanji unterstützt, durch Transfer Learning auf die synthetischen Kobani-Daten anpassen, um eine hohe Übersetzungsqualität zu erreichen?

Das vortrainierte NLLB-200-distilled-600M-Modell konnte durch Transfer Learning auf den synthetischen Kobani-Daten deutlich verbessert werden (siehe Tabelle 5.1). Diese Verbesserung zeigt sich deutlich in allen drei automatischen Metriken (BLEU, chrF++ und TER) für das fine-tuned Modell. Die Verbesserungen sind besonders ausgeprägt bei den Perturbationen, die durch das regelbasierte Perturbationssystem umgesetzt wurden. Die qualitative Analyse der 60 zufällig

ausgewählten Übersetzungsbeispielen (siehe Abschnitt 5.4) bestätigt, dass das fine-tuned NLLB-200-distilled-600M-Modell in vielen Fällen grammatikalisch korrektere und näher an der KV liegende Übersetzungen produziert.
Fazit zu Forschungsfrage 2: Das vortrainierte NLLB-200-distilled-600M-Modell lässt sich durch Transfer Learning auf synthetische Kobani-Daten gut und sinnvoll anpassen. Eine hohe Übersetzungsqualität ist mit diesem Ansatz und ausschließlich synthetischen Daten jedoch nicht erreichbar. Der hybride Ansatz mit synthetischen Daten und Fine-tuning stellt somit einen wertvollen ersten Schritt dar. Für Anwendungsfälle wie grobes Textverständnis ist er nutzbar, jedoch für die Anforderungen mit hoher Genauigkeit ist die Übersetzungsqualität noch deutlich unzureichend.

6.3 Limitationen der Arbeit

In dieser Arbeit wurde gezeigt, dass der hybride Ansatz viele Verbesserungen mit sich bringt (siehe Tabelle 5.1), jedoch weist er mehrere Limitationen auf. Diese Limitationen begrenzen die Übersetzungsqualität und können wie folgt aufgelistet werden:

- **Datenknappheit:** Auch die Daten von Opus können das Problem der Datenknappheit nicht beheben- nach dem Filtern standen nur noch 823.001 Sätze zur Verfügung (siehe Abschnitt 3.2).

- **Unvollständige linguistische Regeln:** Nicht alle relevanten linguistischen Regeln der KV konnten extrahiert und implementiert werden, z. B. Kopulaphrasen (siehe Abschnitt 4.3).

- **Unvollständiger Wortschatz:** Das selbst erstellte Wörterbuch deckt die Kobani-spezifische Lexik noch nicht ganz vollständig ab (siehe Abschnitt 4.2).

- **Sprachunterschiede zwischen Standardsprache und Alltagssprache:** Das Ausgangsmaterial ist in der Standardsprache (Kurmanji), Kobani hingegen ist Umgangssprache. Dieser Unterschied konnte nicht ganz ausgeglichen werden.

6.4 Übertragbarkeit und zukünftige Forschung

Der in dieser Arbeit verwendete hybride Ansatz ist grundsätzlich auf andere Varianten des Kurmanji übertragbar, insbesondere auf die **Suruç-Variante**[2], bei der nahezu alle linguistischen Merkmale identisch zur KV sind. Hier müsste lediglich das Wörterbuch angepasst werden.

Zukünftige Forschung könnte sich auf folgende Aspekte konzentrieren:

- **Verbesserung der PoS-Tagging-Basis:** Zukünftige Arbeiten könnten durch den Einsatz eines noch präziseren PoS-Taggers die Qualität der regelbasierten Perturbation weiter steigern. Obwohl der verwendete **NK-XLMR**-Tagger [26] eine gute Gesamtgenauigkeit von *0,87* aufweist, zeigt sich eine Limitation insbesondere bei der Identifikation von Adverbien (Fehlerrate 0,73).

- **Mixed fine-tuning:** Kombination synthetischer Daten mit kleinen Mengen echter paralleller Kobani-Daten, z. B. den MTACR[3]-Daten.

- **Nutzerzentrierte Evaluation** durch Kobani-Muttersprachler zur Bewertung der praktischen Nutzbarkeit.

Die vorliegende Arbeit hat gezeigt, dass die maschinelle Übersetzung von unterrepräsentierten Sprachvarianten des Nordkurdischen (Kurmanji) von Transfer-Learning-Ansätzen, welche auf synthetischen Daten aufbauen, profitieren können. Die gesammelten Erkenntnisse können zukünftige Forschungsbestrebungen motivieren, während die öffentliche Bereitstellung der fine-tuned Modelle[4] und Skripte zur synthetischen Datengenerierung freie Forschung in diesen Bereichen unterstützen.

[2] Gesprochen im kurdischen Teil der Türkei (Bakur) https://en.wikipedia.org/wiki/SuruÃğ
[3] https://www.hcl.uni-hamburg.de/ddlitlab/data-literacy-studierendenprojekte/dritte-foerderrunde/textcorpus.html
[4] https://huggingface.co/RamanAhmad/nllb-distilled-600m-kob_Latn-to-eng https://huggingface.co/RamanAhmad/nllb-distilled-600m-eng-to-kob_Latn

Literaturverzeichnis

[1] Ahmadi, Sina ; Masoud, Maraim: Towards Machine Translation for the Kurdish Language. In: *Proceedings of the 3rd Workshop on Technologies for MT of Low Resource Languages*. Suzhou, China : Association for Computational Linguistics, 2020, S. 87–98. – URL https://aclanthology.org/2020.loresmt-1.12. – Zugriffsdatum: 2025-06-26

[2] Ahmadi, Sina ; Sennrich, Rico ; Karami, Erfan ; Marani, Ako ; Fekrazad, Parviz ; Baghban, Gholamreza A. ; Hadi, Hanah ; Heidari, Semko ; Dogan, Mahîr ; Asadi, Pedram ; Bashir, Dashne ; Ghodrati, Mohammad A. ; Amini, Kourosh ; Ashourinezhad, Zeynab ; Baladi, Mana ; Ezzati, Farshid ; Ghasemifar, Alireza ; Hosseinpour, Daryoush ; Abbaszadeh, Behrooz ; Hassanpour, Amin ; Hamaamin, Bahaddin J. ; Hama, Saya K. ; Mousavi, Ardeshir ; Hussein, Sarko N. ; Nejadgholi, Isar ; Ölmez, Mehmet ; Osmanpour, Horam ; Ramezani, Rashid R. ; Aziz, Aryan S. ; Salehi Sheikhalikelayeh, Ali ; Yadegari, Mohammadreza ; Yadegari, Kewyar ; Roodsari, Sedighe Z.: PARME: Parallel Corpora for Low-Resourced Middle Eastern Languages. In: Che, Wanxiang (Hrsg.) ; Nabende, Joyce (Hrsg.) ; Shutova, Ekaterina (Hrsg.) ; Pilehvar, Mohammad T. (Hrsg.): *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Vienna, Austria : Association for Computational Linguistics, Juli 2025, S. 30032–30053. – URL https://aclanthology.org/2025.acl-long.1451/. – Zugriffsdatum: 2025-11-14. – ISBN 979-8-89176-251-0

[3] Anderson, Catherine ; Bjorkman, Bronwyn ; Denis, Derek ; Doner, Julianne ; Grant, Margaret ; Sanders, Nathan ; Taniguchi, Ai: *Essentials of Linguistics, 2nd edition*. eCampusOntario, Februar 2022. – URL https://ecampusontario.pressbooks.pub/essentialsoflinguistics2/. – Zugriffsdatum: 2025-10-19. – ISBN 978-1-927565-50-6

[4] Ashti Afrasyaw, J. ; Kayhan, S. K.: A Brief Overview of Kurdish Natural Language Processing. In: *Proceedings of Workshop on Intelligent Information Systems*, 2021, S. 185

[5] Bahdanau, Dzmitry ; Cho, Kyunghyun ; Bengio, Yoshua: *Neural Machine Translation by Jointly Learning to Align and Translate.* Mai 2016. – URL http://arxiv.org/abs/1409.0473. – Zugriffsdatum: 2025-06-15. – arXiv:1409.0473 [cs]

[6] Bedir-Xan, C.A. ; Lescot, R.: *Kurdische Grammatik: Kurmancî-Dialekt.* Kurd. Inst., Dt. Sekt, 1986 (Disputationes linguarum et cultuum Orbis. Sectio K, Disputationes Linguae et Cultus Kurdica). – URL https://books.google.de/books?id=GVL6ygAACAAJ. – ISBN 978-3-926105-51-6

[7] Bird, Steven: Local Languages, Third Spaces, and Other High-Resource Scenarios. In: Muresan, Smaranda (Hrsg.) ; Nakov, Preslav (Hrsg.) ; Villavicencio, Aline (Hrsg.): *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers).* Dublin, Ireland : Association for Computational Linguistics, Mai 2022, S. 7817–7829. – URL https://aclanthology.org/2022.acl-long.539. – Zugriffsdatum: 2024-07-08

[8] Bogoychev, Nikolay ; Linde, Jelmer van d. ; Nail, Graeme ; Haddow, Barry ; Zaragoza-Bernabeu, Jaume ; Ramírez-Sánchez, Gema ; Weymann, Lukas ; Mateiu, Tudor N. ; Helcl, Jindřich ; Aulamo, Mikko: *OpusCleaner and OpusTrainer, open source toolkits for training Machine Translation and Large language models.* November 2023. – URL http://arxiv.org/abs/2311.14838. – Zugriffsdatum: 2025-09-07. – arXiv:2311.14838 [cs]

[9] Eisele, Andreas ; Chen, Yu: MultiUN: A Multilingual Corpus from United Nation Documents. (2010)

[10] Fan, Angela ; Bhosale, Shruti ; Schwenk, Holger ; Ma, Zhiyi ; El-Kishky, Ahmed ; Goyal, Siddharth ; Baines, Mandeep ; Celebi, Onur ; Wenzek, Guillaume ; Chaudhary, Vishrav ; Goyal, Naman ; Birch, Tom ; Liptchinsky, Vitaliy ; Edunov, Sergey ; Grave, Edouard ; Auli, Michael ; Joulin, Armand: *Beyond English-Centric Multilingual Machine Translation.* Oktober 2020. – URL http://arxiv.org/abs/2010.11125. – Zugriffsdatum: 2025-11-14. – arXiv:2010.11125 [cs]

[11] Goyle, Vakul ; Krishnaswamy, Parvathy ; Ravikumar, Kannan G. ; Chattopadhyay, Utsa ; Goyle, Kartikay: *Neural Machine Translation For Low Resource Languages.* April 2023. – URL http://arxiv.org/abs/2304.07869. – Zugriffsdatum: 2025-04-04. – arXiv:2304.07869 [cs]

[12] Gökirmak, Memduh ; Tyers, Francis M.: A Dependency Treebank for Kurmanji Kurdish. (2017)

[13] Haddow, Barry ; Bawden, Rachel ; Barone, Antonio Valerio M. ; Helcl, Jindřich ; Birch, Alexandra: Survey of Low-Resource Machine Translation. In: *Computational Linguistics* 48 (2022), September, Nr. 3, S. 673–732. – URL https://direct.mit.edu/coli/article/48/3/673/111479/Survey-of-Low-Resource-Machine-Translation. – Zugriffsdatum: 2025-06-25. – ISSN 0891-2017, 1530-9312

[14] Haig, Geoffrey ; Öpengin, Ergin: Kurmanji Kurdish in Turkey: Structure, Varieties, and Status. In: *Linguistic minorities in Turkey and Turkic-speaking minorities of the periphery* (2018), S. 157–229. – URL https://fis.uni-bamberg.de/handle/uniba/45103. – Zugriffsdatum: 2023-05-25. ISBN 9783447107235

[15] Hassani, Hossein: Kurdish Interdialect Machine Translation. In: *Proceedings of the Fourth Workshop on NLP for Similar Languages, Varieties and Dialects (VarDial)*. Valencia, Spain : Association for Computational Linguistics, 2017, S. 63–72. – URL http://aclweb.org/anthology/W17-1208. – Zugriffsdatum: 2025-04-06

[16] Hazim M. Ameen, Hakar ; Ali Ahmed, Hussein: Assessing the Quality of Machine Translation from Kurmanji Kurdish into English. In: *Academic Journal of Nawroz University* 12 (2023), August, Nr. 3, S. 503–517. – URL https://journals.nawroz.edu.krd/index.php/ajnu/article/view/1690. – Zugriffsdatum: 2025-07-09. – Publisher: Nawroz University. – ISSN 2520-789X

[17] Hedderich, Michael A. ; Lange, Lukas ; Adel, Heike ; Strötgen, Jannik ; Klakow, Dietrich: *A Survey on Recent Approaches for Natural Language Processing in Low-Resource Scenarios*. April 2021. – URL http://arxiv.org/abs/2010.12309. – Zugriffsdatum: 2025-06-03. – arXiv:2010.12309 [cs]

[18] Hosna, Asmaul ; Merry, Ethel ; Gyalmo, Jigmey ; Alom, Zulfikar ; Aung, Zeyar ; Azim, Mohammad A.: Transfer learning: a friendly introduction. In: *Journal of Big Data* 9 (2022), Nr. 1, S. 102. – URL https://pmc.ncbi.nlm.nih.gov/articles/PMC9589764/. – Zugriffsdatum: 2025-10-19. – ISSN 2196-1115

[19] Joshi, Aditya ; Dabre, Raj ; Kanojia, Diptesh ; Li, Zhuang ; Zhan, Haolan ; Haffari, Gholamreza ; Dippold, Doris: Natural Language Processing for Dialects of a Language: A Survey. In: *ACM Comput. Surv.* 57 (2025), Februar, Nr. 6, S. 149:1–149:37. – URL https://dl.acm.org/doi/10.1145/3712060. – Zugriffsdatum: 2025-02-28. – ISSN 0360-0300

[20] Joshi, Pratik ; Santy, Sebastin ; Budhiraja, Amar ; Bali, Kalika ; Choudhury, Monojit: The State and Fate of Linguistic Diversity and Inclusion in the NLP World. In: Jurafsky,

Dan (Hrsg.) ; Chai, Joyce (Hrsg.) ; Schluter, Natalie (Hrsg.) ; Tetreault, Joel (Hrsg.): *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Online : Association for Computational Linguistics, Juli 2020, S. 6282–6293. – URL https://aclanthology.org/2020.acl-main.560. – Zugriffsdatum: 2023-12-05

[21] Kirkpatrick, James ; Pascanu, Razvan ; Rabinowitz, Neil ; Veness, Joel ; Desjardins, Guillaume ; Rusu, Andrei A. ; Milan, Kieran ; Quan, John ; Ramalho, Tiago ; Grabska-Barwinska, Agnieszka ; Hassabis, Demis ; Clopath, Claudia ; Kumaran, Dharshan ; Hadsell, Raia: Overcoming catastrophic forgetting in neural networks. In: *Proceedings of the National Academy of Sciences* 114 (2017), März, Nr. 13, S. 3521–3526. – URL http://arxiv.org/abs/1612.00796. – Zugriffsdatum: 2026-01-10. – arXiv:1612.00796 [cs]. – ISSN 0027-8424, 1091-6490

[22] Kuchimova, Gulmera: THE THEORY OF AGGLUTINATION AND THE PROBLEMS OF STUDYING THE MORPHEMICS OF TURKIC LANGUAGES. (2023)

[23] Lagarda, A.-L. ; Alabau, V. ; Casacuberta, F. ; Silva, R. ; Liaño, E. Díaz-de: Statistical post-editing of a rule-based machine translation system. In: *Proceedings of Human Language Technologies: The 2009 Annual Conference of the North American Chapter of the Association for Computational Linguistics, Companion Volume: Short Papers on - NAACL '09*. Boulder, Colorado : Association for Computational Linguistics, 2009, S. 217. – URL http://portal.acm.org/citation.cfm?doid=1620853.1620913. – Zugriffsdatum: 2025-06-14

[24] Lopez, Adam: Statistical machine translation. In: *ACM Computing Surveys* 40 (2008), August, Nr. 3, S. 1–49. – URL https://dl.acm.org/doi/10.1145/1380584.1380586. – Zugriffsdatum: 2025-06-15. – ISSN 0360-0300, 1557-7341

[25] Magueresse, Alexandre ; Carles, Vincent ; Heetderks, Evan: *Low-resource Languages: A Review of Past Work and Future Challenges*. Juni 2020. – URL http://arxiv.org/abs/2006.07264. – Zugriffsdatum: 2025-06-26. – arXiv:2006.07264 [cs]

[26] Morad, Peshmerge ; Ahmadi, Sina ; Gatti, Lorenzo: Part-of-Speech Tagging for Northern Kurdish. (2024)

[27] Naveen, Palanichamy ; Trojovský, Pavel: Overview and challenges of machine translation for contextually appropriate translations. In: *iScience* 27 (2024), Oktober, Nr. 10, S. 110878. – URL https://linkinghub.elsevier.com/retrieve/pii/S2589004224021035. – Zugriffsdatum: 2025-06-14. – ISSN 25890042

[28] Pan, Sinno J. ; Yang, Qiang: A Survey on Transfer Learning. In: *IEEE Transactions on Knowledge and Data Engineering* 22 (2010), Oktober, Nr. 10, S. 1345–1359. – URL http://ieeexplore.ieee.org/document/5288526/. – Zugriffsdatum: 2025-10-05. – ISSN 1041-4347

[29] Papineni, Kishore ; Roukos, Salim ; Ward, Todd ; Zhu, Wei-Jing: BLEU: a method for automatic evaluation of machine translation. In: *Proceedings of the 40th Annual Meeting on Association for Computational Linguistics - ACL '02*. Philadelphia, Pennsylvania : Association for Computational Linguistics, 2001, S. 311. – URL http://portal.acm.org/citation.cfm?doid=1073083.1073135. – Zugriffsdatum: 2025-12-21

[30] Papineni, Kishore ; Roukos, Salim ; Ward, Todd ; Zhu, Wei-Jing: Bleu: a method for automatic evaluation of machine translation. In: *Proceedings of the 40th annual meeting of the Association for Computational Linguistics*, URL https://aclanthology.org/P02-1040.Pdf. – Zugriffsdatum: 2025-11-03, 2002, S. 311–318

[31] Pei, Jiaxin ; Ananthasubramaniam, Aparna ; Wang, Xingyao ; Zhou, Naitian ; Dedeloudis, Apostolos ; Sargent, Jackson ; Jurgens, David: POTATO: The Portable Text Annotation Tool. In: Che, Wanxiang (Hrsg.) ; Shutova, Ekaterina (Hrsg.): *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. Abu Dhabi, UAE : Association for Computational Linguistics, Dezember 2022, S. 327–337. – URL https://aclanthology.org/2022.emnlp-demos.33/. – Zugriffsdatum: 2025-12-22

[32] Popović, Maja: chrF: character n-gram F-score for automatic MT evaluation. In: Bojar, Ondřej (Hrsg.) ; Chatterjee, Rajan (Hrsg.) ; Federmann, Christian (Hrsg.) ; Haddow, Barry (Hrsg.) ; Hokamp, Chris (Hrsg.) ; Huck, Matthias (Hrsg.) ; Logacheva, Varvara (Hrsg.) ; Pecina, Pavel (Hrsg.): *Proceedings of the Tenth Workshop on Statistical Machine Translation*. Lisbon, Portugal : Association for Computational Linguistics, September 2015, S. 392–395. – URL https://aclanthology.org/W15-3049/. – Zugriffsdatum: 2025-11-03

[33] Popović, Maja: chrF++: words helping character n-grams. In: Bojar, Ondřej (Hrsg.) ; Buck, Christian (Hrsg.) ; Chatterjee, Rajen (Hrsg.) ; Federmann, Christian (Hrsg.) ; Graham, Yvette (Hrsg.) ; Haddow, Barry (Hrsg.) ; Huck, Matthias (Hrsg.) ; Yepes, Antonio J. (Hrsg.) ; Koehn, Philipp (Hrsg.) ; Kreutzer, Julia (Hrsg.): *Proceedings of the Second Conference on Machine Translation*. Copenhagen, Denmark : Association for Computational Linguistics,

September 2017, S. 612–618. – URL https://aclanthology.org/W17-4770/. – Zugriffsdatum: 2025-12-29

[34] Qi, Peng ; Zhang, Yuhao ; Zhang, Yuhui ; Bolton, Jason ; Manning, Christopher D.: *Stanza: A Python Natural Language Processing Toolkit for Many Human Languages.* April 2020. – URL http://arxiv.org/abs/2003.07082. – Zugriffsdatum: 2025-09-30. – arXiv:2003.07082 [cs]

[35] Ramasamy, Loganathan: Morphological Processing for English-Tamil Statistical Machine Translation. (2012)

[36] Snover, Matthew ; Dorr, Bonnie ; Schwartz, Rich ; Micciulla, Linnea ; Makhoul, John: A Study of Translation Edit Rate with Targeted Human Annotation. In: *Proceedings of the 7th Conference of the Association for Machine Translation in the Americas: Technical Papers.* Cambridge, Massachusetts, USA : Association for Machine Translation in the Americas, August 2006, S. 223–231. – URL https://aclanthology.org/2006.amta-papers.25/. – Zugriffsdatum: 2025-12-29

[37] Strunk, Jan: The structure of the Kurdish noun phrase. (2003)

[38] Sutskever, Ilya ; Vinyals, Oriol ; Le, Quoc V.: *Sequence to Sequence Learning with Neural Networks.* Dezember 2014. – URL http://arxiv.org/abs/1409.3215. – Zugriffsdatum: 2025-12-17. – arXiv:1409.3215 [cs]

[39] Tang, Yuqing ; Tran, Chau ; Li, Xian ; Chen, Peng-Jen ; Goyal, Naman ; Chaudhary, Vishrav ; Gu, Jiatao ; Fan, Angela: *Multilingual Translation with Extensible Multilingual Pretraining and Finetuning.* August 2020. – URL https://arxiv.org/abs/2008.00401v1. – Zugriffsdatum: 2025-11-14

[40] Team, NLLB ; Costa-jussà, Marta R. ; Cross, James ; Çelebi, Onur ; Elbayad, Maha ; Heafield, Kenneth ; Heffernan, Kevin ; Kalbassi, Elahe ; Lam, Janice ; Licht, Daniel ; Maillard, Jean ; Sun, Anna ; Wang, Skyler ; Wenzek, Guillaume ; Youngblood, Al ; Akula, Bapi ; Barrault, Loic ; Gonzalez, Gabriel M. ; Hansanti, Prangthip ; Hoffman, John ; Jarrett, Semarley ; Sadagopan, Kaushik R. ; Rowe, Dirk ; Spruit, Shannon ; Tran, Chau ; Andrews, Pierre ; Ayan, Necip F. ; Bhosale, Shruti ; Edunov, Sergey ; Fan, Angela ; Gao, Cynthia ; Goswami, Vedanuj ; Guzmán, Francisco ; Koehn, Philipp ; Mourachko, Alexandre ; Ropers, Christophe ; Saleem, Safiyyah ; Schwenk, Holger ; Wang, Jeff ; Ai, Meta: No Language Left Behind: Scaling Human-Centered Machine Translation. (2022). – URL https://arxiv.org/abs/2207.04672

[41] Vaswani, Ashish ; Shazeer, Noam ; Parmar, Niki ; Uszkoreit, Jakob ; Jones, Llion ; Gomez, Aidan N. ; Kaiser, Lukasz ; Polosukhin, Illia: *Attention Is All You Need.* August 2023. – URL http://arxiv.org/abs/1706.03762. – Zugriffsdatum: 2025-06-18. – arXiv:1706.03762 [cs]

[42] W. M. Thackston: *Kurmanji Kurdish: A Reference Grammar with Selected Readings.* URL http://archive.org/details/thackston-2006-kurmanji-grammar-readings. – Zugriffsdatum: 2025-11-11, 2006

[43] Wolf, Thomas ; Debut, Lysandre ; Sanh, Victor ; Chaumond, Julien ; Delangue, Clement ; Moi, Anthony ; Cistac, Pierric ; Rault, Tim ; Louf, Rémi ; Funtowicz, Morgan ; Davison, Joe ; Shleifer, Sam ; Platen, Patrick v. ; Ma, Clara ; Jernite, Yacine ; Plu, Julien ; Xu, Canwen ; Scao, Teven L. ; Gugger, Sylvain ; Drame, Mariama ; Lhoest, Quentin ; Rush, Alexander M.: *HuggingFace's Transformers: State-of-the-art Natural Language Processing.* Juli 2020. – URL http://arxiv.org/abs/1910.03771. – Zugriffsdatum: 2025-12-17. – arXiv:1910.03771 [cs]

[44] Xu, Weijia ; Agrawal, Sweta ; Briakou, Eleftheria ; Martindale, Marianna J. ; Carpuat, Marine: Understanding and Detecting Hallucinations in Neural Machine Translation via Model Introspection. In: *Transactions of the Association for Computational Linguistics* 11 (2023), S. 546–564. – URL https://aclanthology.org/2023.tacl-1.32/. – Zugriffsdatum: 2026-01-15. – Place: Cambridge, MA Publisher: MIT Press

[45] Zhuang, Fuzhen ; Qi, Zhiyuan ; Duan, Keyu ; Xi, Dongbo ; Zhu, Yongchun ; Zhu, Hengshu ; Xiong, Hui ; He, Qing: *A Comprehensive Survey on Transfer Learning.* Juni 2020. – URL http://arxiv.org/abs/1911.02685. – Zugriffsdatum: 2025-10-19. – arXiv:1911.02685 [cs]

A Anhang

A.1 OpusCleaner Filters

```
{
  "version": 1,
  "files": [
    "NLLB-v1.en-ku_Latn.en.gz",
    "NLLB-v1.en-ku_Latn.ku_Latn.gz"
  ],
  "filters": [
    {
      "filter": "max_length",
      "parameters": {
        "MAXLENGTH": 150,
        "MINLENGTH": 1
      },
      "language": null
    },
    {
      "filter": "opus.AverageWordLengthFilter",
      "parameters": {
        "min_length": 1,
        "max_length": 100,
        "pass_empty": false
      },
      "language": null
    },
    {
      "filter": "langid",
      "parameters": {
        "SRC_LANG": "en",
        "TRG_LANG": "ku",
        "ALLOW_SIMILAR": true,
        "ALLOW_UNKNOWN": true,
        "DEBUG": null
      },
      "language": null
    },
    {
      "filter": "url_mismatch",
      "parameters": {
        "DEBUG": false
      },
      "language": null
    },
    {
      "filter": "deescape_tsv",
      "parameters": {},
      "language": null
    },
    {
      "filter": "currency_mismatch",
      "parameters": {
```

```
51          "DEBUG": false,
52          "FIX": false
53        },
54        "language": null
55      },
56      {
57        "filter": "fix_wiki",
58        "parameters": {
59          "ALWAYS": false,
60          "FOOTNOTES": true,
61          "URLS": true,
62          "WIKILINKS": true,
63          "CODE": true,
64          "HEADINGS": true,
65          "REMOVEEMPTYLINES": true
66        },
67        "language": null
68      },
69      {
70        "filter": "normalize_whitespace",
71        "parameters": {
72          "COLLAPSE": true
73        },
74        "language": "en,ku_Latn"
75      },
76      {
77        "filter": "opus.HtmlTagFilter",
78        "parameters": {},
79        "language": null
80      },
81      {
82        "filter": "opus.RegExpSub",
83        "parameters": {
84          "patterns": [
85            [
86              "\u00fe",
87              "\u015f",
88              0,
89              ""
90            ],
91            [
92              "\u017a",
93              "\u00ea",
94              0,
95              ""
96            ],
97            [
98              "\u017e",
99              "\u015f",
100             0,
101             ""
102           ]
103         ]
104       },
105       "language": "en,ku_Latn"
106     },
107     {
108       "filter": "num_mismatch",
109       "parameters": {
110         "RATIO": 1,
111         "DEBUG": false
112       },
113       "language": null
114     },
115     {
116       "filter": "remove_empty_lines",
117       "parameters": {},
118       "language": null
119     },
```

```
120     {
121       "filter": "alpha_ratio",
122       "parameters": {
123         "LANG1": "en",
124         "LANG2": "ku",
125         "SRCWORDRAT": 0.4,
126         "TRGWORDRAT": 0.4,
127         "SRCALPHARAT": 0.5,
128         "TRGALPHARAT": "0.7",
129         "DEBUG": false
130       },
131       "language": null
132     },
133     {
134       "filter": "src_trg_ratio",
135       "parameters": {
136         "RATIO": 0.6,
137         "LOG": false
138       },
139       "language": null
140     },
141     {
142       "filter": "fix_sent_final_punct",
143       "parameters": {},
144       "language": null
145     }
146   ]
147 }
```

Listing A.1: Konfiguration der in opusCleaner verwendeten Filter

A.1.1 OpusFilter Ergebniss

Tabelle A.1: Alle Filters in OpusCleaner mit Beispielen für Englisch-Kurmanji

Filtername	Zweck	Einstellung	Gefiltertes Paar / gefixte / betroffene
max_length	Begrenzt die maximale Satzlänge	MAX: 150 Tokens	Keine Wirkung
langid	Erkennt automatisch die Sprache	SRC_LANG: en und TRG_-LANG: ku	Keine Wirkung
opus.AverageWordLengthFilter	Prüft die durchschnittliche Wortlänge	Default	Keine Wirkung
remove_empty_lines	Entfernt leere Zeilen	Default	Keine Wirkung
url_mismatch	Entfernt Segmente bei URL-Abweichungen	Default	Keine Wirkung
deescape_tsv	Entfernt doppelte Anführungszeichen um TSV-Felder	default	**vorher**: "We have heard and disobeyed." **nachher**: We have heard and disobeyed.
currency_mismatch	Vergleich von Währungen	default	**en**:(Many people will save $150 or more right off the bat!) **ku**: (Divê € 100 niha ji bo ku heqê herî zêde bigire!)
fix_wiki	Entfernt Wikipedia-Markup wie Wikilinks, Klammern und Listenzeichen	default	**vorher**: The name comes from the [[Nahuatl language]], but its meaning is unknown. **nachher**: The name comes from the Nahuatl language, but its meaning is unknown.
normalize_whitespace	Entfernt überflüssige Leerzeichen und Tabs	default	**vorher**: Contact us___ today_ for more information. **nachher**: Contact us today for more information.
alpha_ratio	Verhältnis Buchstaben/Symbole	TRGALPHARAT: 0.7	**en**: More than 10 years: 4 percent **ku**: Ji 40 livî zêdetir: % 60
opus.HtmlTagFilter	Entfernt HTML-Tags aus Segmenten	default	**vorher**: Lê ez tu care jî nabim şirîkê xeletiyê. Xazî (Tevgera Yekitiya Îslamî): Xwedê piştevanê hemû mazlûman bibe. **nachher**: Lê ez tu care jî nabim şirîkê xeletiyê. Xazî (Tevgera Yekitiya Îslamî): Xwedê piştevanê hemû mazlûman bibe.

Filtername	Zweck	Einstellung	Gefiltertes Paar / gefixte / betroffene
opus.RegExpSub	Ersetzt Text mithilfe von regulären Ausdrücken (Pattern → Replacement)	Pattern: þ → ş Pattern: ž → ş Pattern: ź → ê	**vorher**: Dema artê**þ** tê gotin **þ**er tê bîra mirov. **nachher**: Dema artê**ş** tê gotin **ş**er tê bîra mirov.
src_trg_ratio	Prüft Längenverhältnis Quelle/Ziel	Ratio: 0.6	**en**: of them are little-known. **ku**: Ne ku nasnameya wan nîne, yên ku wan nas dikin pir kêm in.
num_mismatch	Zahlenvergleich Quelle/Ziel	default	**en**: On March 14, she went to her aunt's house and went missing. **ku**: Di 16 ê îlonê de li mala mamê xwe ji qata çaremîn a malê avêt û xwest xwe bikuje.
fix_sent_final_punct	Korrigiert fehlende oder abweichende Satzendzeichen	Default	**en**: Come in with Facebook. **ku vorher**: Bi Facebook re têkevinê **ku nachher**: Bi Facebook re têkevinê**.**

A.2 Hyperparameter des Fine-tunings

```
num_train_epochs: 10
per_device_train_batch_size: 4
gradient_accumulation_steps: 8
eval_steps: 2000
save_steps: 2000
save_total_limit: 3
early_stopping_patience: 3
```

Listing A.2: Hyperparameter-Konfiguration des Fine-tunings (beide Übersetzungsrichtungen identisch)

A.3 Übersetzungsergebnisse

Tabelle A.2: Alle ausgewählten Übersetzungsbeispiele: Referenz vs. Modellhypothese

Satz-ID	Ähnl. (%)	Referenz und Hypothese
		Sehr hohe Ähnlichkeit (80–100 %)
1	100.0	**Referenz**: A window pop wê zihar bibe. **Hypothese**: A window pop wê zihar bibe.
2	100.0	**Referenz**: 36 Loma, eger Kur we azad bikê, bi rastî hûnê azad bibin. **Hypothese**: 36 Loma, eger Kur we azad bikê, bi rastî hûnê azad bibin.
3	100.0	**Referenz**: 18 Wek ku te ez şandim dinyayê, min jî ew şandin dinyayê. **Hypothese**: 18 Wek ku te ez şandim dinyayê, min jî ew şandin dinyayê.
4	100.0	**Referenz**: 18 Wek ku te ez şandim dinyayê, min jî ew şandin dinyayê. **Hypothese**: 18 Wek ku te ez şandim dinyayê, min jî ew şandin dinyayê.
5	100.0	**Referenz**: 24 Heta niha we bi navê min tu tişt nexwest. **Hypothese**: 24 Heta niha we bi navê min tu tişt nexwest.
6	100.0	**Referenz**: 6 Merîyak ji alê Xwedê va hatibû şandin ku navê wî Yûhenna bû. **Hypothese**: 6 Merîyak ji alê Xwedê va hatibû şandin ku navê wî Yûhenna bû.
7	100.0	**Referenz**: 20 deqeyan da herî kêm. **Hypothese**: 20 deqeyan da herî kêm.
8	100.0	**Referenz**: 6 Merîyak ji alê Xwedê va hatibû şandin ku navê wî Yûhenna bû. **Hypothese**: 6 Merîyak ji alê Xwedê va hatibû şandin ku navê wî Yûhenna bû.
9	100.0	**Referenz**: 6 Lê dema bihîst ku Lazar nexweş e, ew du rojên din jî li wî cihê ku lê bû ma. **Hypothese**: 6 Lê dema bihîst ku Lazar nexweş e, ew du rojên din jî li wî cihê ku lê bû ma.
10	100.0	**Referenz**: 18 Wek ku te ez şandim dinyayê, min jî ew şandin dinyayê. **Hypothese**: 18 Wek ku te ez şandim dinyayê, min jî ew şandin dinyayê.
11	100.0	**Referenz**: 18 Wek ku te ez şandim dinyayê, min jî ew şandin dinyayê. **Hypothese**: 18 Wek ku te ez şandim dinyayê, min jî ew şandin dinyayê.

12	100.0	**Referenz**: navê we yek e. **Hypothese**: navê we yek e.
13	100.0	**Referenz**: 20 kes jî mirinê. **Hypothese**: 20 kes jî mirinê.
14	100.0	**Referenz**: 38 Çimkî ez ji ezmên hatim xwarê, ne sebî ku ez daxwaza xwe bikim, lê sebî ku ez daxwaza yê ku ez şandimê bikim. **Hypothese**: 38 Çimkî ez ji ezmên hatim xwarê, ne sebî ku ez daxwaza xwe bikim, lê sebî ku ez daxwaza yê ku ez şandimê bikim.
15	100.0	**Referenz**: 6 Lê dema bihîst ku Lazar nexweş e, ew du rojên din jî li wî cihê ku lê bû ma. **Hypothese**: 6 Lê dema bihîst ku Lazar nexweş e, ew du rojên din jî li wî cihê ku lê bû ma.
16	100.0	**Referenz**: 23 salî ye. **Hypothese**: 23 salî ye.
17	100.0	**Referenz**: 18 Wek ku te ez şandim dinyayê, min jî ew şandin dinyayê. **Hypothese**: 18 Wek ku te ez şandim dinyayê, min jî ew şandin dinyayê.
18	100.0	**Referenz**: 6 Merîyak ji alê Xwedê va hatibû şandin ku navê wî Yûhenna bû. **Hypothese**: 6 Merîyak ji alê Xwedê va hatibû şandin ku navê wî Yûhenna bû.
Mittlere Ähnlichkeit (40–60 %)		
19	55.6	**Referenz**: Di rêya şaş da ye. **Hypothese**: di rêya xwe da.
20	55.6	**Referenz**: Ajalnasî (3 endam) **Hypothese**: Theodicy (3 endam)
21	55.3	**Referenz**: The software pir bi îstîqrar bi kar e. **Hypothese**: The software pir gihîştî ye.
22	55.2	**Referenz**: 10 Lê piştî ku birayên wî çûn cejnê, ew jî rabû çû, lê belê ne bi eşkereyî, ji dizî va. **Hypothese**: 10 lê piştî ku birayên wî çûn cejnê, ew jî çû, lê belê ne bi eşkereyî, ji kesekî ra.
23	55.2	**Referenz**: Di dawiya fîlm da sernakevim. **Hypothese**: di dawiya fîlm da.
24	55.0	**Referenz**: Çavkaniya înternetê. **Hypothese**: ên li ser înternetê.
25	55.0	**Referenz**: Tenê sebî sûka Çînê. **Hypothese**: , lê tenê sebî Çînê.
26	55.0	**Referenz**: Dua bikin, sebî min. **Hypothese**: . dua bikê sebî min.
27	55.0	**Referenz**: Çalakî roja yekem... **Hypothese**: roja xwe ya yekem...
28	54.8	**Referenz**: Va di dîroka Tirkiyê da lekeyeke reş e. **Hypothese**: ut di dîroka Tirkiyê da cihê guhertinê ye.
29	54.5	**Referenz**: Erê bitikînin sebî afirandina da. **Hypothese**: ereya listing sebî afirandina.
30	54.5	**Referenz**: di heman rojê da ayný gün **Hypothese**: di heman rojê da di heman rojê da
31	54.5	**Referenz**: Di dîroka merê da cara pêşî! **Hypothese**: di dîroka merê da nehatiye kirin!
32	54.2	**Referenz**: Di dawê da ez li vir. **Hypothese**: ya talî lê ez li vir im.
33	54.2	**Referenz**: A: Warranty yek salî ye. **Hypothese**: : Garantiya yek salî ye.
34	53.8	**Referenz**: The software bibe dibînê. **Hypothese**: The software hatiye dîtin.
35	53.6	**Referenz**: Lê Swêdê ew yek qebûl nekir. **Hypothese**: , lê gelê wî ew qebûl nekir.
36	53.6	**Referenz**: Va kê tenê çend deqe bidomê. **Hypothese**: ut bi tenê çend deqiqe.
Sehr niedrige Ähnlichkeit (0–20 %)		
37	11.0	**Referenz**: Di heman demê da di rewşê da têkilê baş ên hevkarê bi hilberên navxweyî ra biparêzê, bi awayek çalak hilberên nû pêşve bibe, xerîdarên nû û domdar pêdivê mişterê li malê û derveyî bicîh bînê. **Hypothese**: di heman demê da sebî qorînkirina têkilê baş yên hevkarê bi manufacturers navxweyî, bi aktîv pêş berhemên nû, mişterê nû û her û her pêdivê mişterê li malê û li derveyî welêt.
38	11.0	**Referenz**: Hinek ji wan ê di demeka nêzîk da di televizyonên asmanî û lokal da jî bên gotin. **Hypothese**: ut di van dems da kê li Austin Area û hinek kesên din bi rêya teleconferencing da bê kirin.
39	11.0	**Referenz**: Geres em vê rasteqînê bibînin ku rêxistinên me nikanin bibin bersiva pêwîstê têkoşîna me... **Hypothese**: kirin ku baweriya me bi hiqûqê me ya hiqûqê ra tinê ku li hember gefên wan bisekinin...
40	11.0	**Referenz**: Kek Nurî Sinir di jîyana xwe a sîyasî da doh jî û îro jî cihê xwe ê bi rûmet girtîye. **Hypothese**: by the Me kingsitei Rubaiyan, qesra niha di bin zeviyan lê hê jî birûmetbûna hey rojên xwe.
41	11.0	**Referenz**: Her wanî navend sebî pêşxistin û xurtkirina şarezayên zarîyan dewrê havînê vedikê. **Hypothese**: ve dikê sebî başkirina asta û sixureê xwarinê sebî dibistanan di zivistanê da.
42	11.0	**Referenz**: Dema ku amedakarîya min biqedê, we projeyek bi sazen nu albuma 3. be li darxistin. **Hypothese**: , da ku ez e gotûbêjekê li ser Pretenders 3rd album binivîsim.

43	11.0	**Referenz**: sîstema (departman, karekî, û hwd.) analîz bi dest bixê têgihiştinekê temam of it. **Hypothese**: system (department, job, etc.) to get a full understanding of it.
44	11.0	**Referenz**: Eger em xwedî pirsgirêka kalîtê, em serhildanên an şûna mal an bişînin dayinên we. **Hypothese**: ên te ne, eger pirsgirêk hebê, em e te biguherînin an jî bidin te.
45	11.0	**Referenz**: E. P.: Li gor we ger ku dewlet piştevaniya Zazakî bikê, kê bibe zimanekî serbixwe? **Hypothese**: : Eger hêza ku li ser bedenekê hereket dikê, eger beden be zero be?
46	11.0	**Referenz**: Xema kesî nînê, ku bi hezara evdên bê sûc û guneh dibin qurbanê van pilanên qilêr. **Hypothese**: anî ziman ku kesek xerab bê ceza nabê, lê serkeftin ji yê rast kê xilas bibe.
47	11.0	**Referenz**: Muzîk û huner sebî wan gelek girîng e, ji ber ku ew navnîşana nasnameya wan e. **Hypothese**: un an jî merasîmên pir girîng in sebî wan ji ber ku ew perçeyek ji ol û adetên in.
48	11.0	**Referenz**: şerefxan Cizirî, di hemendem da diyar dikê ku eşîr civatekê xwedê heq û hiqûqê ye. **Hypothese**: ut e, va nîşan dide ku va hê jî civakeke bi rûmet û dil e.
49	11.0	**Referenz**: Got; heger hun lê ên şehîdan digerin van e ên şehîdan li vir in. **Hypothese**: , got, eger intruder sebî agahê bi vî awayî digeriyen, ew li cihê ne rast digerin.
50	11.0	**Referenz**: li tiştekî şermê ye herî hûn di jiyana karê te çi kirê çi ye? **Hypothese**: ya vê yekê ye, geres bê gotin ku nexweşê wê tinê ne û bikaranîna wê tê qorînkirin.
51	11.0	**Referenz**: Va e hê çiqas bêtir bi qulayî ji eyar spacers û dikarin demeke din jî rizgar bikê. **Hypothese**: ya giranbiha ya dabînkirina dabînkerî ya bingeha karkirinê ya bingeha karkirinê.
52	11.0	**Referenz**: Gava mêrikê dikandar şêxê me nasdikê dêjê, kuro Xwedê ji te sitandê, ma te ne bihîstê ku bisilman li we Êzdiyan digerin û te çewa cesaret kirê werî vêderê? **Hypothese**: ên gelek merê ku bi xwe ra rû bi rû bûn, ji xwe ra rû bi rû bûn, ji xwe ra rû bi rû man, ji xwe ra rû bi rû man, ji xwe ra rû bi rû man.
53	11.0	**Referenz**: Kesên ku her salê carekî be jî diçin welat û tên jî vê mijarê fêm nakin. **Hypothese**: e ku va e ku ew kesên ku dem bi dem, sal bi sal in, ku negihîjê her derê.
54	11.0	**Referenz**: Hikûmeta AKP CPT û Konseya Ewropa di vê komployê da rolên sereke dilîzin. **Hypothese**: ut ewropayê û Civata Parlamentarî di vî warîî da xwedê rolên sereke ne.

A.4 Glossar

NLLB-Base-Modell Bezeichnung für das vortrainierte NLLB-200-distilled-600M-Modell von Meta, das in dieser Arbeit als Baseline verwendet wird.

Regelbasierter Ansatz Eigenentwickelter Ansatz zur maschinellen Übersetzung, bei dem die Trainingsdaten anhand eines selbst erstellten Wörterbuchs und eigener linguistischer Regeln aufbereitet werden.

Perturbierte Daten Daten, die mithilfe eigener linguistischer Regeln sowie des selbst erstellten Wörterbuchs verändert (perturbiert) wurden.

A.5 Verwendete Hilfsmittel

In der Tabelle A.3 sind die im Rahmen der Bearbeitung des Themas der Bachelorarbeit verwendeten Werkzeuge und Hilfsmittel aufgelistet.

Tabelle A.3: Verwendete Hilfsmittel und Werkzeuge

Tool	Verwendung
LaTeX	Textsatz- und Layout-Werkzeug verwendet zur Erstellung dieses Dokuments
Python	Programmiersprache für die gesamte Implementierung
Hugging Face Transformers	Bibliothek zur Nutzung und zum Fine-Tuning des NLLB-Modells
NLLB-200-distilled-600M	Vortrainiertes multilinguales Übersetzungsmodell (Basis für Transfer Learning)
OpusCleaner / OPUS	Bereinigung und Filterung der parallelen NLLB-Daten
Stanza	NLP-Bibliothek für linguistische Annotation (PoS-Tagging)
NK-XLMR PoS-Tagger	Spezieller PoS-Tagger für Northern Kurdish (NK)
Git / GitHub	Versionskontrolle des Codes
gpu-v100-01.ml.inf.haw-hamburg.de	HAW-Hardware (GPU) für das Fine-Tuning des Modells

Erklärung zur selbständigen Bearbeitung

Hiermit versichere ich, dass ich die vorliegende Arbeit in allen Teilen selbstständig angefertigt und keine anderen als die in der Arbeit angegebenen Quellen und Hilfsmittel benutzt habe. Die in meiner Arbeit verwendeten KI-basierten Hilfsmittel habe ich (ggf. mit Produktnamen) angegeben.

Ich verantworte die Übernahme jeglicher von mir verwendeter maschinell generierter Passagen vollumfänglich selbst und trage die Verantwortung für eventuell durch die KI generierte fehlerhafte oder verzerrte Inhalte, fehlerhafte Referenzen, Verstöße gegen das Datenschutz- und Urheberrecht oder Plagiate.

Mir ist bewusst, dass wahrheitswidrige Angaben als Täuschungsversuch behandelt werden können.

Ort	Datum	Unterschrift im Original